

Warum die Arbeit ihren eigenen Zahlen so wenig traut

Band 1 hat erklärt, was untersucht wurde und was herauskam. Dieser Band geht dahinter: Wie die Daten überhaupt entstanden sind, warum aus 4.752 Zeilen nur 39 belastbare Einheiten werden, was die Suche nach den richtigen Einstellungen in Wahrheit findet — und ob ein solches Modell seine Fehler gerecht verteilt.

Anschluss an: „Kann man ausrechnen, wo die Feuerwehr gebraucht wird?“ Fachbegriffe aus Band 1 werden hier vorausgesetzt; neue sind beim ersten Auftreten erklärt und im Glossar am Ende gesammelt.

Abbildungen: fortlaufend ab Nummer 13

TEIL 6

Wie aus sieben Beständen eine Tabelle wird

Band 1 zeigte einen Trichter: sieben Quellen rein, eine Tabelle raus. Was in diesem Trichter passiert, ist der größte Teil der Arbeit — und der Teil, in dem die folgenschwersten Entscheidungen fallen. Drei davon lohnen eine genauere Betrachtung.

Erstens: Die Zeitfalle

Ein Modell soll etwas vorhersagen. Das klingt selbstverständlich, hat aber eine harte Konsequenz: Es darf ausschließlich mit Informationen rechnen, die zum Zeitpunkt der Vorhersage *schon existierten*. Wer diese Regel verletzt, baut ein Modell, das hervorragende Werte erreicht und trotzdem nichts vorhersagt — es liest die Antwort ab. Der Fachbegriff dafür ist **Datenleckage**.


In dieser Arbeit gibt es zwei Stellen, an denen die Falle zuschnappen könnte. Die erste sind die Einsatzmeldungen selbst. Sie enthalten Felder, die erst *nach* dem Einsatz feststehen: geschätzter Sachschaden, Zahl der Löschfahrzeuge, Löschkräfte, RettungsdienstEinheiten, Alarmstufe, Antwortzeit, Ankunftszeitpunkt, zivile Tote, zivile Verletzte, und ob die Flammenausbreitung eingedämmt wurde. Zehn Felder, die eng mit der Zielgröße zusammenhängen. Ein Modell mit ihnen erreichte glänzende Werte — und wäre wertlos.

Die Arbeit sperrt sie nicht erst beim Modellieren, sondern *beim Einlesen*. Was gar nicht erst in die Datei gelangt, kann später nicht versehentlich in ein Modell geraten. Und dass wirklich keines den Weg hineinfindet, wird nicht behauptet, sondern automatisiert geprüft.

Zweitens: Der Publikationsversatz

Die zweite Falle ist subtiler und betrifft die Sozialdaten. Die amerikanische Statistikbehörde veröffentlicht Fünfjahresschätzungen: Der Jahrgang 2023 bündelt die Erhebungen von 2019 bis 2023 und erscheint erst *nach* deren Ablauf. Für einen Einsatz im Jahr 2023 war der Jahrgang 2023 also noch gar nicht verfügbar.

EIN EINSATZ IM JULI 2019 — WELCHE SOZIALDATEN GAB ES DAMALS?



Die Regel lautet: **ACS-Jahrgang höchstens Einsatzjahr minus eins**. Sie steht als benannte Konstante an einer einzigen Stelle im Code — nicht verstreut in der Rechnung, wo sie niemand mehr fände.

Abbildung 13: Der Publikationsversatz der Sozialdaten. Die Zeitachse ist zur Veranschaulichung gewählt; die Regel selbst — Jahrgang höchstens Einsatzjahr minus eins — steht wörtlich so in der Arbeit.

Diese Regel wird nicht auf die fertige Monatstabelle angewendet, sondern auf *jeden einzelnen Einsatz*. Der Grund ist zwingend: Nur der einzelne Einsatz trägt einen eigenen Zeitpunkt. Verdichtet man erst und ordnet

danach zu, ist die Information, welcher Stand damals galt, bereits verloren. Die Zwischentabelle hat deshalb 719.989 Zeilen und 50 Spalten — eine Zeile je Einsatz.

Nach demselben Gedanken ist auch der Kriminalitätsindex gebaut. Er misst nicht die Kriminalität *dieses* Monats, sondern die der **zwölf Vormonate**. Eine im selben Monat gemessene Kriminalität würde die Einsätze dieses Monats erklären statt sie vorherzusagen.

Drittens: Zwei Karten, die nicht zueinander passen

Die Sozialdaten liegen für kleine statistische Bezirke vor, die Arbeit rechnet aber auf Stadtteilen. Es braucht also eine Übersetzungstabelle — einen **Crosswalk**. Der Haken: Die Behörde zieht diese Bezirksgrenzen periodisch neu. Die verwendete Übersetzungstabelle folgt den Grenzen von 2020, zwei der genutzten Jahrgänge aber noch denen von 2010.

Über die reine Kennung greift die Zuordnung deshalb nur für 79,7 % der Bezirke. Aufgefangen wird das über den vierstelligen Basiscode der Bezirksnummer: Wird ein Bezirk geteilt, behält er ihn und ändert nur das Suffix. Damit steigt die Quote auf 99,2 bis 99,5 %. Und die Aufbereitung bricht ab, sobald weniger als 95 % der Einwohner eines Jahrgangs zugeordnet sind.

WARUM DIESE SCHWELLE DA STEHT

Sie ist keine Sorgfaltsroutine, sondern die Lehre aus einem konkreten Fehler. Ein reiner Gleichheitsverbund verwarf 40 der 197 Bezirke zweier Jahrgänge — und mit ihnen **gut ein Viertel der Wohnbevölkerung**, konzentriert in den geteilten Bezirken der Innenstadt. Eine Zuordnung, die stillschweigend Zeilen verliert, fällt in keiner Gütekennzahl auf. Sie muss beim Einlesen auffallen, oder sie fällt nie auf.

Dasselbe Muster wiederholt sich an jeder Nahtstelle: Vor jedem Verbund wird die Eindeutigkeit des Schlüssels geprüft, nach jedem die Zeilenzahl gegen den Erwartungswert gehalten. Insgesamt hängen 20 Einzelprüfungen an der fertigen Datei. Zwei davon prüfen nicht eine Einstellung, sondern das erwartete Ergebnis: dass genau 36 Stadtteile enthalten sind und dass die stadtweite Einwohnerzahl in einer plausiblen Spanne liegt — sie liegt zwischen 811.572 und 856.270.

Was ausgeschlossen wurde, und warum als Ganzes

Fünf der 41 Stadtteile scheiden aus: die Parkanlagen Golden Gate Park, Lincoln Park und McLaren Park ohne nennenswerte Wohnbevölkerung sowie Lakeshore und Treasure Island, für die das Parzellenverzeichnis kein einziges Baujahr führt.

Entscheidend ist die *Form* dieses Ausschlusses: Entfernt werden vollständige Stadtteile, nie einzelne Monate. Ein zeilenweises Verwerfen erzeugte ein löchriges Raster, in dem ein Stadtteil mitten in der Zeitreihe hinzuträte. Umgekehrt bekommt jeder Monat ohne Einsatz eine Zeile mit dem Wert null — nicht gar keine Zeile. Ein rechteckiges Raster ist die Voraussetzung dafür, dass die fünf Prüfgruppen aus Band 1 überhaupt miteinander vergleichbar sind.

Am Ende stehen 4.752 Zeilen für die Menge und 4.751 für die Art — dem Strukturdatensatz fehlt der eine Monat ohne Einsatz, weil sich ihm keine überwiegende Einsatzart zuordnen lässt.

TEIL 7

Warum 4.752 Zeilen nur 39 Einheiten sind

Das ist die Grenze, die in der Arbeit alle anderen bindet. Sie erklärt, warum am Ende fast kein Unterschied zwischen den Verfahren statistisch absicherbar ist — und sie hat nichts damit zu tun, dass jemand schlecht gerechnet hätte.

Der Gedanke dahinter

Stellen Sie sich vor, Sie wollen wissen, wie groß erwachsene Menschen im Schnitt sind, und messen dafür eine Person 132-mal nach. Sie haben dann 132 Messwerte — aber Sie wissen noch immer nur, wie groß *eine* Person ist. Die 132 Zahlen sind nicht 132 unabhängige Informationen, sie sind eine, 132-mal wiederholt.

Genau in dieser Lage ist die Arbeit. Sie hat 36 Stadtteile über 132 Monate. Aber die Merkmale eines Stadtteils bewegen sich zwischen Januar und Februar praktisch nicht. Drei von ihnen — die baulichen — sind über die vollen elf Jahre buchstäblich konstant. Die 132 Zeilen eines Stadtteils sind also weitgehend dieselbe Information, 132-mal wiederholt.

Wie stark, lässt sich messen. Das Maß heißt **Intraklassenkorrelation** und beantwortet: Wie viel der gesamten Schwankung liegt *zwischen* den Stadtteilen statt *innerhalb* eines Stadtteils über die Zeit? Für die Einsatzhäufigkeit beträgt sie 0,926 — 92,6 % der Schwankung ist eine Sache des Ortes, nicht des Monats.

WIE VIEL UNABHÄNGIGE INFORMATION STECKT IN EINER SPALTE?

Rechnerisch entspricht der Bestand so vielen wirklich unabhängigen Beobachtungen:



Die drei baulichen Merkmale ändern sich in elf Jahren **gar nicht** — ihre 4.752 Zeilen tragen exakt 36 Informationen.

Abbildung 14: Die effektive Stichprobengröße je Spalte, berechnet aus der Intraklassenkorrelation. Nur die beiden Saisonterme, die sich ausschließlich innerhalb eines Stadtteils bewegen, schöpfen die 4.752 Zeilen wirklich aus. Werte aus der Varianzzerlegung im Projektordner, gerundet.

Aus der Intraklassenkorrelation und der Zahl der Monate folgt der **Designeffekt** — der Faktor, um den man die Zeilenzahl herunterrechnen muss. Er beträgt hier 122. Und 4.752 geteilt durch 122 ergibt rund **39**.

Das ist keine Schätzung am Rande, sondern die Zahl, an der in der Arbeit alles hängt. Sie erklärt, warum die Aufteilung nach Stadtteilen erfolgt: Weil der Stadtteil die Einheit ist, nicht die Zeile. Und sie erklärt die nächste Zahl.

Was ein Test mit 39 Einheiten noch erkennen kann

Ein statistischer Test kann einen Unterschied übersehen, der wirklich da ist. Wie oft das passiert, hängt von zwei Dingen ab: wie groß der Unterschied ist und wie viel unabhängige Information vorliegt. Die Wahrscheinlichkeit, einen vorhandenen Unterschied auch zu finden, heißt **Trennschärfe**.

Die Arbeit rechnet sie für ihr eigenes Design aus — mit 4.000 simulierten Ziehungen. Das Ergebnis ist ernüchternd und sollte vor jeder Interpretation der p-Werte aus Band 1 stehen:

WIE WAHRSCHEINLICH FINDET DER TEST EINEN UNTERSCHIED, DEN ES WIRKLICH GIBT?




Abbildung 15: Die Trennschärfekurve aus der Simulation der Arbeit (4.000 Ziehungen, zehn Paare). Die drei Punkte markieren die tatsächlich gemessenen Abstände der drei Verfahren zur Poisson-Baseline. Erst ab einem Abstand von etwa 0,84 werden Vergleiche in dieser Arbeit signifikant.

WAS DARAUS FÜR BAND 1 FOLGT

Die drei nicht signifikanten Vergleiche gegen die Baseline — Ridge mit $p = 0,275$, Random Forest mit $0,922$, XGBoost mit $0,275$ — sind **keine Aussage über Gleichheit**. Sie sind eine Aussage über die Auflösung dieses Designs. Die Arbeit schreibt das selbst so hin: Bei den gemessenen Abständen hätte der Test einen echten Unterschied in 60 bis 89 % der Fälle gar nicht bemerkt.

Umgekehrt gilt aber auch: Was *doch* signifikant wird, ist deshalb umso belastbarer. Ridge gegen XGBoost hätte der Test mit 99 % Wahrscheinlichkeit gefunden — dieser Befund steht.

Warum die Arbeit nicht einfach mehr Daten nimmt

Der naheliegende Einwand lautet: Dann rechnet man eben über einen längeren Zeitraum. Die Arbeit entkräftet ihn in einem Satz — ein zusätzliches Jahr brächte 432 weitere Zeilen und **keinen einzigen weiteren Stadtteil**. Die Einheit ist der Ort, und von Orten gibt es 36.

Es gibt noch eine zweite Stelle, an der dieselbe Logik greift. Die Arbeit bewertet 50 Rechenläufe, testet aber nur auf zehn Werten. Der Grund ist derselbe: Die 50 Läufe sind dieselben 30 Stadtteile in wechselnder Gruppierung; ihre Übungsmengen überlappen einander. Sie als 50 unabhängige Messungen zu behandeln, wäre **Pseudoreplikation** — man täte so, als hätte man fünfmal so viel Information wie tatsächlich. Die Arbeit verzichtet deshalb bewusst auf Trennschärfe und testet auf den zehn Wiederholungsmitteln. Der Preis dafür ist genau die geringe Auflösung, die Abbildung 15 zeigt.

Noch eine Grenze: Das Modell wird nach Unbekanntem gefragt

Ein Entscheidungsbaum kann nur Werte vorhersagen, die er im Training gesehen hat. Bekommt er einen Stadtteil vorgelegt, dessen Armutsquote höher liegt als alles, was in seinen Übungsdaten vorkam, ordnet er ihn schlicht dem nächstgelegenen bekannten Fall zu. Das nennt man **Extrapolation** — und die Arbeit misst, wie oft das passiert.

DIE 30 ENTWICKLUNGSSTADTTEILE — ANTEIL DER ZEILEN AUßERHALB DES GELERNTEN BEREICHS



Es ist kein sanfter Übergang, sondern alles oder nichts: **11 der 30 Stadtteile liegen vollständig außerhalb** dessen, was das Modell gelernt hat — darunter Tenderloin und Seacliff, die beiden Extreme der Stadt.

Abbildung 16: Jede Kachel ist ein Stadtteil in der ersten Wiederholung. Über alle fünfzig Läufe liegen 36,6 % der Testzeilen außerhalb des gelernten Bereichs, auf den sechs zurückgehaltenen Stadtteilen 34,8 %. Werte aus dem Projektordner; die Kachelanordnung ist frei gewählt.

Bemerkenswert daran ist, was *nicht* folgt. Man würde erwarten, dass gerade die Baumverfahren darunter leiden, weil nur sie diese Schwäche haben. Gemessen ist das Gegenteil: Der Zusammenhang zwischen dem Extrapolationsanteil eines Laufs und dem dort erreichten Fehler ist bei Ridge am stärksten (+0,335) und beim Random Forest am schwächsten (+0,249). Wäre die Extrapolation der Hebel gegen die Baumverfahren, müsste es umgekehrt sein. Sie erklärt deren Rückstand also nicht — was bleibt, ist eine Eigenschaft des Prüfrahmens selbst.

TEIL 8

Überanpassung — wenn ein Modell auswendig lernt

In Band 1 stand dieser Begriff im Glossar und danach kaum wieder. Dabei ist er die wahrscheinlichste Erklärung für den überraschendsten Befund der Arbeit: dass die aufwendigen Verfahren gegen ein schlichtes Modell verlieren.

Zwei Zahlen, die man nebeneinander lesen muss

Für jedes Verfahren gibt es zwei Güteangaben. Die eine sagt, wie gut es die *Übungsstadtteile* beschreibt, die es kennt. Die andere, wie gut es die *Prüfstadtteile* trifft, die es nie gesehen hat. Bei einem Schüler wären das die Hausaufgaben und die Klausur.

Solange beide Werte nah beieinanderliegen, hat das Modell etwas verstanden. Klafft eine Lücke, hat es auswendig gelernt.

ERKLÄRTE SCHWANKUNG — AUF DEN ÜBUNGSSTADTTEILEN GEGEN NEUE STADTTEILE




Abbildung 17: Werte aus Tabelle 16 der Arbeit. Alle drei Verfahren verlieren beim Sprung auf unbekannte Stadtteile — die beiden Baumverfahren aber zweieinhalbmal so viel wie Ridge.

Was daran auffällt

Auf den Übungsstadtteilen sind die Baumverfahren *besser* als Ridge: 0,965 und 0,975 gegen 0,842. Auf neuen Stadtteilen sind sie *schlechter*: 0,498 und 0,486 gegen 0,655. Beide Aussagen stammen aus demselben Rechenlauf.

Genau das ist der Mechanismus, den Band 1 nur als Ergebnis berichtet hat. Die Baumverfahren nutzen ihre Flexibilität — sie bilden die 24 Übungsstadtteile fast perfekt nach. Nur besteht das, was sie dabei nachbilden, zu einem großen Teil aus Eigenheiten dieser 24 Stadtteile und nicht aus einer übertragbaren Regel.

Am deutlichsten wird es in der Schlussbewertung auf den sechs zurückgehaltenen Stadtteilen: Dort erreicht XGBoost auf seinen Trainingsdaten ein Bestimmtheitsmaß von **0,997** — es beschreibt die 30 Entwicklungsstadtteile praktisch fehlerfrei. Auf den sechs unbekannten kommt es auf 0,691.

WARUM DAS KEIN BEDIENFEHLER IST

Man könnte denken, die Bremsen seien schlecht eingestellt. Dagegen spricht, dass die Arbeit für jedes Verfahren 100 Einstellungskombinationen durchprobiert hat, und zwar für jede Prüfgruppe einzeln — genau um diese Lücke klein zu halten. Die Lücke bleibt trotzdem. Sie ist eine Folge der Datenlage aus Teil 7: Bei 24 Übungsstadtteilen gibt es schlicht zu wenig, aus dem sich eine übertragbare Regel gewinnen ließe, und zu viel, das sich auswendig lernen lässt.

Bei der Einsatzart wiederholt sich das Muster in kleinerem Maßstab: Der Random Forest erreicht auf den Übungsdaten ein Macro-F1 von 0,582 und auf neuen Stadtteilen 0,318, XGBoost 0,480 gegen 0,301.

Durften diese Verfahren überhaupt antreten?

Bevor irgendein Modell gerechnet wurde, hat die Arbeit geprüft, ob die Daten zu den Verfahren passen. Das Ergebnis dieser Prüfung ist nicht nur formal interessant — es steht in einem lehrreichen Widerspruch zu dem, was am Ende herauskam.

Die Ausgangslage

Die Beweislast liegt bei den aufwendigen Verfahren. Das schlichte Poisson-Modell funktioniert bereits; wer mehr Aufwand treiben will, muss begründen, warum. Die Frage ist dabei nicht, *ob* das lineare Modell rechnet, sondern ob seine Bauform zur Struktur der Daten passt. Sie unterstellt zwei Dinge: dass jedes Merkmal über seinen gesamten Wertebereich gleich wirkt, und dass diese Wirkung nicht davon abhängt, welche Werte die anderen Merkmale annehmen.

Beides hält einer Prüfung nicht stand — und die Arbeit prüft es mit benannten Verfahren statt nach Augenmaß.

ZWÖLF ANFORDERUNGEN, GEPRÜFT AUF DEN 24 ÜBUNGSSTADTTEILEN DER ERSTEN PRÜFGRUPPE

- **Unabhängige Beobachtungen — verletzt**
betrifft alle fünf Verfahren gleichermaßen · Folge: Aufteilung nach Stadtteilen statt zufällig (Teil 7)
- **Gleiche Höhe und Streuung der Zählgröße — verletzt, Teststatistik 18,0**
die Streuung ist rund 80-mal größer als sie sein dürfte · Folge: folgenlos, da nur Punktvorhersagen berichtet werden
- **Gerader Zusammenhang zwischen Merkmalen und Ziel — verletzt, Teststatistik 360,4**
betrifft Poisson-Modell und Ridge · Folge: Ridge rechnet auf einer gestauchten Skala
- **Gleichmäßige Fehlerstreuung — verletzt, Teststatistik 525,1**
Folge: betrifft die Unsicherheitsangaben, nicht die Vorhersage selbst — und diese Angaben werden hier nicht berichtet
- **Testpunkte im gelernten Wertebereich — verletzt, 38,2 % außerhalb**
betrifft Random Forest und XGBoost · Folge: als Limitation ausgewiesen (Abbildung 16)
- **Erfüllt oder nicht erforderlich: identische Daten für alle Verfahren, Normalverteilung der Fehler, Verteilungsannahme der Baumverfahren, passende Verlustfunktion, jede Klasse in jeder Prüfgruppe**

Abbildung 18: Tabelle 8 der Arbeit, zusammengefasst. Von zwölf geprüften Anforderungen sind sechs verletzt und zwei für das jeweilige Verfahren gar nicht zu stellen. Entscheidend ist die rechte Spalte der Originaltabelle: Fast alle Verletzungen betreffen die *Unsicherheitsangaben*, nicht die Vorhersage.

Zwei Ursachen, benannt

Krümmung. Der Zusammenhang zwischen Merkmal und Zielgröße verläuft nicht gerade. Der verwendete Test nimmt die Vorhersagewerte des Modells, fügt ihre Potenzen als zusätzliche Merkmale hinzu und misst, ob die Anpassung dadurch besser wird. Sie wird deutlich besser. Sichtbar ist dasselbe auch schlichter: Auf den 24 Übungsstadtteilen weichen die beiden Zusammenhangsmaße bei der Armutsquote am stärksten voneinander ab — +0,342 gegen +0,617. (Die Werte in Band 1 unterscheiden sich davon, weil sie über alle 36 Stadtteile gerechnet sind.)

Wechselwirkungen. Ergänzt man das lineare Modell um alle 45 paarweisen Produkte der zehn Merkmale, steigt die erklärte Schwankung von 0,859 auf 0,932. Es gibt also Zusammenspiele, die ein rein additives Modell nicht erfasst.

Aus beidem folgt genau die Verfahrenswahl der Arbeit: Ein lineares Modell braucht für Krümmung vorab festgelegte Transformationen und für Wechselwirkungen von Hand eingefügte Produktterme — für deren Auswahl es keine Regel gibt. Baumverfahren brauchen beides nicht.

UND JETZT DER WIDERSPRUCH

Die Eignungsprüfung sagt: Die lineare Form reicht nicht. Das Ergebnis aus Band 1 sagt: Ridge sagt unbekannte Stadtteile trotzdem am genauesten vorher.

Die Arbeit löst das nicht auf, sondern zeigt, wo der Fehlschluss steckt. Beide Befunde der Eignungsprüfung beziehen sich auf *dieselben Zeilen, an denen das Modell angepasst wurde*. Sie belegen, dass die lineare Form die vorliegenden Stadtteile schlechter beschreibt als eine flexiblere Form — nicht, dass sie unbekannte Stadtteile schlechter *vorhersagt*. Das sind zwei verschiedene Aussagen, und die Gegenprobe aus Band 1 (Abbildung 12) zeigt, dass sie hier sogar gegenläufig ausfallen: Jede Erweiterung, die das Modell besser *beschreiben* lässt, macht seine Vorhersagen dramatisch schlechter.

Daraus zieht die Arbeit ihre übertragbare Regel: Nachweisbare Nichtlinearität im Anpassungsdatensatz begründet für sich genommen noch kein flexibleres Verfahren.

Was ausdrücklich nicht verglichen wurde

Zur Eignungsprüfung gehört auch die umgekehrte Begründung. Lasso und Elastic Net scheiden aus, weil sie Koeffizienten auf null setzen und damit Merkmale aussortieren — sie würden genau die Faktorgruppen entfernen, deren Erklärungsbeitrag die erste Unterfrage prüfen soll. Neuronale Netze scheiden aus, weil 36 Analyseeinheiten für sie zu wenig sind. Und die Ridge Regression tritt bei der Einsatzart nicht an, weil sie den quadratischen Fehler minimiert und dieser auf vier ungeordneten Kategorien nicht definiert ist.

TEIL 10

Was die Suche nach den Einstellungen wirklich findet

Vor jedem Rechenlauf steht eine Suche: Welche Einstellungen soll das Verfahren bekommen? Sie ist der größte Einzeleposten des ganzen Projekts — 10.000 Modellanpassungen, rund 137 Minuten. Und sie fördert etwas zutage, das man nicht erwartet.

Wie gesucht wird

Die *Hyperparameter* dürfen die Prüfdaten nicht kennen. Gesucht wird deshalb in einer *zweiten, inneren* Aufteilung innerhalb der Übungsstadtteile: Vier innere Gruppen, wieder nach Stadtteilen getrennt, wieder so, dass ein Stadtteil mit allen 132 Monaten entweder im inneren Training oder in der inneren Prüfung steht — nie in beidem.


Gezogen wird zufällig, hundertmal je Suchlauf. Warum hundert und nicht fünfzig, ist ausgerechnet und nicht geraten: Mit hundert zufälligen Ziehungen trifft man einen Zielbereich, der fünf Prozent des Suchraums ausmacht, mit 99,4 % Wahrscheinlichkeit mindestens einmal — bei fünfzig sind es 92,3 %.

Dabei fällt eine Ungleichheit auf, die die Arbeit offenlegt: Ridge hat **einen** einstellbaren Parameter, XGBoost hat **sieben**. Beide bekommen dasselbe Budget von hundert Ziehungen. Hundert Versuche decken einen Raum mit sieben Stellschrauben deutlich dünner ab als einen mit einer. Dass daraus kein messbarer Nachteil für XGBoost entsteht, zeigt der nächste Abschnitt.

Der eigentliche Befund

Die Suche liefert je Prüfgruppe einen eigenen Parametersatz — fünf Sätze insgesamt. Eine naheliegende Gegenprobe: Was passiert, wenn man jede Prüfgruppe nicht mit *ihrem* Satz bewertet, sondern mit einem, der auf ganz anderen Stadtteilen gefunden wurde?

FEHLER MIT DEM EIGENEN GEGEN EINEN FREMDEN PARAMETERSATZ (RMSE)



Bei beiden Baumverfahren ist der eigens gesuchte Satz im Mittel **schlechter** als ein auf fremden Daten gefundener.

Abbildung 19: Jede Prüfgruppe wurde mit jedem der fünf gefundenen Parametersätze bewertet. Werte aus der Parametersensitivität im Projektordner, erste Wiederholung — sie liegen deshalb nicht exakt auf den Hauptergebnissen aus Band 1.

Das Ergebnis ist bemerkenswert: Beim Random Forest ist der eigens gesuchte Satz im Mittel um 1,85 RMSE *schlechter* als ein fremder, bei XGBoost um 1,05. Nur bei Ridge bringt er einen kleinen Vorteil von 0,46.

Man kann das auch von der anderen Seite betrachten: Innerhalb *derselben* Prüfgruppe trennen die fünf Parametersätze bei Ridge 2,54 RMSE, beim Random Forest 4,91 und bei XGBoost 9,14. Zur Erinnerung an Band 1: Der gesamte Abstand zwischen dem besten und dem schwächsten Verfahren beträgt 6,5. Die Wahl des Parametersatzes bewegt das Ergebnis bei XGBoost also stärker als die Wahl des Verfahrens.

Woher das kommt

Nicht aus einer schlechten Suche. Die Arbeit prüft das eigens: Eine Diagnose schreibt jede der hundert Ziehungen mit ihrem inneren Gütewert mit. Die zweite Hälfte der Suche verbessert den bis dahin besten Wert bei keinem der fünf Verfahren um mehr als 0,020 — gemessen an einer Streuung zwischen den Prüfgruppen, die für dieselben Verfahren zwischen 0,040 und 0,342 liegt. Die Suche war ausgereizt, lange bevor das Budget aufgebraucht war.

Die Ursache ist wieder Teil 7. Bei rund 39 unabhängigen Einheiten schwankt der innere Gütewert stärker, als die Unterschiede zwischen den Parametersätzen groß sind. Die Suche optimiert dann zu einem erheblichen Teil auf Rauschen.

WIE TIEF SOLLTEN DIE BÄUME WACHSEN? — DIE ANTWORT JE PRÜFGRUPPE, EINSATZART




Abbildung 20: Die vom Random Forest gewählte Baumtiefe im Strukturstrang, je Prüfgruppe. Werte aus Tabelle 9 und der Suchdiagnose. XGBoost geht im selben Strang in die Gegenrichtung: dort reichen die gewählten Strafterme von 1,7 bis 9.333.

Praktische Folgerung der Arbeit daraus: Der Aufwandsnachteil der Baumverfahren entsteht nicht erst beim fertigen Modell, sondern vervielfacht sich über die Modellwahl — und was dabei herauskommt, ist zu einem guten Teil von der zufälligen Gruppierung der Stadtteile bestimmt.

TEIL 11

Verteilen sich die Fehler gerecht?

Ein Modell kann im Durchschnitt gut sein und trotzdem systematisch bei bestimmten Stadtteilen danebenliegen. Wenn diese Stadtteile die ärmeren sind, ist das mehr als ein statistisches Detail. Die Arbeit prüft das — und findet etwas Unbequemes.


Die Frage und ihre Tücke

Gemessen wird, ob in Prüfgruppen mit höherer Armutsquote auch der Prognosefehler höher ausfällt. Der Zusammenhang besteht — für jedes einzelne Verfahren, deutlich, mit Rangkorrelationen zwischen +0,39 und +0,81.

Das allein besagt jedoch wenig. In ärmeren Stadtteilen finden schlicht *mehr* Einsätze statt, und ein größerer absoluter Fehler bei gleicher relativer Genauigkeit ist keine Benachteiligung. Wer 200 Einsätze vorhersagt und 20 danebenliegt, ist genauso gut wie jemand, der bei 20 Einsätzen 2 danebenliegt.

Die aussagekräftige Rechnung setzt den Fehler deshalb ins Verhältnis zur mittleren Einsatzzahl der Prüfgruppe. Erst dann zeigt sich, ob wirklich ungleich gut vorhergesagt wird.

ZUSAMMENHANG ZWISCHEN ARMUTSQUOTE DER PRÜFGRUPPE UND PROGNOSEFEHLER



Je länger der untere Balken, desto stärker hängt die Qualität vom Sozialprofil ab. Null wäre Gleichbehandlung.

Abbildung 21: Rangkorrelation über die fünfzig Läufe des Mengenstrangs, Zielgröße Anzahl Einsätze. Werte aus der Fairness-Auswertung im Projektordner; die Arbeit berichtet sie in Kapitel 7.3.

Das unbequeme Ergebnis

Bei den beiden Baumverfahren verschwindet der Zusammenhang nach der Relativierung weitgehend — er sinkt auf +0,18 und +0,15 und ist statistisch nicht mehr absicherbar. Beim Poisson-Modell bleibt dagegen ein deutlicher Rest von +0,60, bei Ridge +0,30.

Das heißt: **Ausgerechnet die Modelle, die im Mittel am genauesten vorhersagen, verteilen ihre Fehler am ungleichmäßigsten über das Sozialprofil der Stadtteile.** Und ausgerechnet die Verfahren, die in Band 1 den kürzeren gezogen haben, behandeln arme und reiche Stadtteile am ähnlichsten.

Bei der bevölkerungsnormierten Zielgröße fällt das Bild gleichsinnig aus: Poisson +0,41, Ridge +0,19, Random Forest +0,01, XGBoost +0,05.

WAS DIESER BEFUND IST — UND WAS NICHT

Geprüft ist die *Gleichheit der Fehler*, nicht die Gerechtigkeit einer daraus abgeleiteten Zuteilung. Die Arbeit sagt das ausdrücklich. Ob ein Modell, das in ärmeren Stadtteilen relativ ungenauer ist, dort am Ende zu wenig oder zu viel Ressourcen zuwiese, hängt an der Richtung des Fehlers und an der Entscheidungsregel darüber — beides untersucht die Arbeit nicht.

Der Befund ändert auch nichts an der Empfehlung aus Band 1, denn eine Rangfolge zwischen den Verfahren lässt die Datenlage ohnehin nur eingeschränkt zu. Er ist ein zusätzlicher Gesichtspunkt, den man kennen sollte, bevor man eines dieser Modelle einsetzt.

Was so ein Modell dürfte — und was nicht

Beim Wort „Vorhersage“ denken viele an Polizeisoftware, die ausrechnet, wo als Nächstes ein Verbrechen passiert. Die Arbeit grenzt sich davon ausdrücklich ab — und die Begründung ist präziser, als man erwarten würde.

Der Unterschied, auf den es ankommt

Die Arbeit bringt ihn auf eine Formel: **Ein Modell, das Einsatzlast vorhersagt, verteilt Hilfe und nicht Kontrolle.**

Ein zusätzlicher Löschzug nützt einem Stadtteil. Zusätzliche Polizeistreifen belasten ihn. Deshalb ist eine Zuteilung nach vorhergesagtem Bedarf in der Notfallversorgung kein Fehler, sondern genau das Ziel — anders als bei der Polizei, wo dieselbe Mechanik zu mehr Kontrolle in ohnehin stärker kontrollierten Vierteln führt.

Diese Entlastung hat allerdings eine Bedingung, und die Arbeit nennt sie mit: Sie gilt nur, *solange der Bedarf nicht über einen Indikator geschätzt wird, dessen Höhe von der Zuteilung selbst abhängt*. Genau hier wird es heikel — denn der stärkste Prädiktor dieser Arbeit ist der Kriminalitätsindex.

WOHER DER KRIMINALITÄTSINDEX WIRKLICH KOMMT

Er stammt aus polizeilichen Meldungen. Polizeiliche Register sind weder eine Vollerhebung aller Delikte noch eine repräsentative Stichprobe daraus. Sie sind das Ergebnis aus drei Dingen: dem tatsächlichen Tatgeschehen, der Bereitschaft der Anwohner, etwas anzuzeigen, und der Intensität, mit der die Polizei dort kontrolliert.

Belegt ist deshalb **nicht**, dass Kriminalität Feuerwehreinsätze erklärt. Belegt ist nur, dass die *registrierte Kriminalitätsbelastung* eines Stadtteils der stärkste verfügbare Einzelindikator für seine Einsatzlast ist. Das ist eine schwächere und ehrlichere Aussage.

Was die Arbeit ausdrücklich nicht tut

Drei Abgrenzungen stehen bereits in Kapitel 4 der Arbeit, also vor dem ersten Ergebnis:

- **Kein Ursachenanspruch.** Geprüft wird, ob die Merkmale einen Beitrag zur Vorhersage leisten — nicht, ob sie Einsätze verursachen.
- **Keine Empfehlung zur Verteilung von Einsatzmitteln.** Die wäre ein eigener Schritt mit eigenen Voraussetzungen.
- **Keine Aussage über einzelne Gebäude oder Haushalte.** Die Ergebnisse gelten auf der Ebene des Stadtteils, und nur dort.

Eine vierte Abgrenzung ist die wichtigste und wird oft übersehen: Sozioökonomische Merkmale können als **Stellvertreter geschützter Eigenschaften** wirken. Armutsquote und Medianmiete stehen nicht nur für sich, sie hängen mit Herkunft und Lebenslage zusammen. Die Übersetzung eines solchen Modells in Ressourcen-

entscheidungen erfordert deshalb eine eigene Prüfung — die diese Arbeit nicht leistet und auch nicht beansprucht zu leisten.

Fünf Grenzen, die man mitdenken muss

GRENZE	WAS GEMESSEN IST
Zu wenige Einheiten	36 Stadtteile, effektiv rund 39 unabhängige Einheiten — ein längerer Zeitraum ändert daran nichts (Teil 7)
Extrapolation	36,6 % der Testzeilen liegen außerhalb des gelernten Bereichs, auf dem Hold-out 34,8 %
Die seltene Klasse	33 branddominierte Monate insgesamt, 2 bis 13 je Prüfgruppe — ein Viertel des Leitmaßes ruht darauf
Zeitliche Auflösung	Sozialdaten jährlich mit Versatz, Flächennutzung eine einzige Momentaufnahme von 2020
Gebietszuschnitt	36 Stadtteile statt 242 kleinerer Bezirke — eine andere Einteilung kann eine andere Rangfolge liefern

Tabelle 17 der Arbeit, gekürzt auf die fünf Punkte mit der größten Wirkung.

Zwei weitere Punkte sind zu konkret, um sie wegzulassen. Erstens folgen die Prüfgruppen der Verwaltungsgrenze und nicht der Reichweite räumlicher Abhängigkeit. Ein Sicherheitsabstand um die Prüfstadtteile herum ließe im Mittel nur 8,6 statt 24 Übungsstadtteile übrig — machbar ist das nicht, und deshalb ist der berichtete Fehler eher zu klein als zu groß.

Zweitens ist die Bezugsgröße die *Wohnbevölkerung*. Für die Innenstadt ist das unvollständig: Financial District/South Beach hat mit 20.044 Einwohnern eine mittlere Wohnbevölkerung, aber mit 10,40 Einsätzen je 1.000 Einwohner die höchste Rate der Stadt — das Vierfache des Medians. Wer dort tagsüber ist, steht in keinem der verwendeten Register.

Und die Antwort auf die Ausgangsfrage

Für die Praxis zieht die Arbeit eine knappe Konsequenz: Wo die Referenz nicht übertroffen wird, ist der produktive Einsatz eines aufwendigeren Verfahrens nicht begründbar. Was übertragbar bleibt, ist keine Zahl, sondern eine Reihenfolge — welche Stadtteile über- und welche unterdurchschnittlich belastet sind, lässt sich aus den Merkmalen ableiten. Die konkrete Einsatzzahl eines einzelnen Stadtteilmonats dagegen nur mit einem mittleren Fehler von rund 20 Einsätzen.

Die neuen Fachbegriffe

Nur die Begriffe, die in Band 1 noch nicht vorkamen. Wie dort: eine Erklärung in einem Satz, ein Beispiel aus dieser Arbeit.

Datenleckage

Ein Modell rechnet mit Informationen, die es zum Zeitpunkt der Vorhersage noch gar nicht geben konnte — es liest die Antwort ab, statt sie zu erraten.

HIER: Die Antwortzeit eines Einsatzes steht erst nach dem Einsatz fest. Sie ist eines von zehn Feldern, die gesperrt wurden.

Publikationsversatz

Der Abstand zwischen dem Zeitraum, den eine Statistik beschreibt, und dem Zeitpunkt, an dem sie veröffentlicht wird.

HIER: Für einen Einsatz im Jahr 2019 durfte höchstens der Sozialdaten-Jahrgang 2018 verwendet werden.

Crosswalk

Eine Übersetzungstabelle zwischen zwei unterschiedlichen Gebietseinteilungen.

HIER: Sie ordnet die kleinen statistischen Bezirke den 41 Stadtteilen zu — für 99,2 bis 99,5 % der Bezirke gelingt das.

Standortquotient

Ein Wert, der eine Größe nicht absolut misst, sondern im Verhältnis zum Durchschnitt des Ganzen. Eins bedeutet „genau wie der Durchschnitt“.

HIER: Der Kriminalitätsindex misst die Deliktrate eines Stadtteils gemessen an der Deliktrate der Gesamtstadt im selben Monat. Das macht ihn unempfindlich dagegen, dass die Polizei mitten im Zeitraum ihr Erfassungssystem gewechselt hat.

Intraklassenkorrelation

Der Anteil der Schwankung, der auf Unterschiede *zwischen* den Gruppen entfällt statt auf Unterschiede innerhalb einer Gruppe.

HIER: 0,926 für die Einsatzhäufigkeit — die Zahl der Einsätze hängt weit mehr daran, welcher Stadtteil es ist, als daran, welcher Monat.

Designeffekt und effektive Stichprobe

Der Faktor, um den man die Zeilenzahl herunterrechnen muss, weil die Zeilen einander ähneln — und das Ergebnis dieser Rechnung.

HIER: Designeffekt 122, also 4.752 geteilt durch 122 und damit rund 39 unabhängige Einheiten. Diese eine Zahl erklärt fast alle Einschränkungen der Arbeit.

Pseudoreplikation

Der Fehler, abhängige Messungen als unabhängige zu behandeln — man tut so, als hätte man mehr Information, als man hat.

HIER: Die Arbeit vermeidet ihn bewusst: Sie rechnet 50 Läufe, testet aber nur auf zehn Werten, weil die 50 Läufe dieselben 30 Stadtteile in wechselnder Gruppierung sind.

Trennschärfe

Die Wahrscheinlichkeit, dass ein statistischer Test einen Unterschied findet, den es wirklich gibt. Das Gegenstück zum p-Wert.

HIER: Bei den gemessenen Abständen zur Baseline nur 11 bis 40 %. Deshalb heißt „nicht signifikant“ in dieser Arbeit vor allem „nicht auflösbar“.

Extrapolation

Ein Modell wird nach einem Wert gefragt, der außerhalb von allem liegt, was es im Training gesehen hat.

HIER: 11 der 30 Stadtteile liegen vollständig außerhalb — ein Baum ordnet sie dem nächstgelegenen bekannten Fall zu, mehr kann er nicht.

Hyperparameter (aus Band 1)

Einstellungen, die vorab festgelegt werden müssen, weil ein Verfahren sie nicht selbst aus den Daten lernen kann.

HIER: Ridge hat einen einzigen, XGBoost hat sieben. Die beiden Baselines haben keinen — das ist der Grund, warum sie als Messlatte taugen.

Rangkorrelation

Ein Maß dafür, ob zwei Größen in derselben Reihenfolge verlaufen — ohne anzunehmen, dass der Zusammenhang gerade ist. Null heißt kein Zusammenhang, eins heißt gleiche Reihenfolge.

HIER: +0,60 zwischen der Armutsquote einer Prüfgruppe und dem relativen Fehler des Poisson-Modells — je ärmer, desto ungenauer.

Stellvertretermerkmal

Ein Merkmal, das formal etwas anderes misst, in der Sache aber eng mit einer geschützten Eigenschaft zusammenhängt.

HIER: Armutsquote und Medianmiete. Die Arbeit benennt das als Grund, warum ihre Ergebnisse nicht ohne eigene Prüfung in Ressourcenentscheidungen übersetzt werden dürfen.

Grundlage dieses Bandes: Bachelorarbeit „Vorhersage von Feuerwehreinsätzen auf Basis struktureller und sozioökonomischer Merkmale" (Stand der vorgelegten Fassung), insbesondere die Abschnitte 4.3, 4.4, 4.5, 5.2, 5.3, 5.4, 6.3, 6.6, 7.2 und 7.3 sowie die Tabellen 8, 9, 16 und 17; ergänzend die Auswertungen im Ordner *results* des Projektverzeichnis — Varianzzerlegung, Eignungsprüfung, Suchdiagnose, Parametersensitivität, Trennschärfe, Fairness und Extrapolation. Alle Zahlenwerte wurden gegen beide Quellen abgeglichen. Wo die Arbeit eine Frage offen lässt, ist das im Text vermerkt und nicht geglättet. Die Abbildungen wurden eigens gezeichnet und sind keine Reproduktionen der Originalabbildungen.