

Kann man ausrechnen, wo die Feuerwehr gebraucht wird?

Eine Bachelorarbeit vergleicht fünf Rechenverfahren, die aus den Merkmalen eines Stadtteils vorhersagen sollen, wie viele Feuerwehreinsätze es dort geben wird — und welcher Art sie sind. Diese Zusammenfassung erklärt ohne Vorkenntnisse, was untersucht wurde und was herauskam.

Titel der Arbeit: „Vorhersage von Feuerwehreinsätzen auf Basis struktureller und sozioökonomischer Merkmale — ein Vergleich ausgewählter Machine-Learning-Methoden am Beispiel von Stadtteildaten“

Autor: Lukas Nießen · FOM Hochschule, Wirtschaftsinformatik (B.Sc.)

Datengrundlage: San Francisco, Januar 2015 bis Dezember 2025

TEIL 1

Aufbau der Arbeit

Die Feuerwehr muss entscheiden, wo sie Wachen, Fahrzeuge und Personal vorhält — und zwar lange bevor der erste Alarm eingeht. Die Arbeit prüft, ob sich der zu erwartende Einsatzbedarf eines Stadtteils allein aus dessen Merkmalen berechnen lässt: Einkommen, Armut, Leerstand, Baujahr der Häuser, Kriminalitätsbelastung. Also aus Daten, die es auch dort gibt, wo noch keine brauchbare Einsatzstatistik vorliegt.

Die Fragestellung

Warum das wichtig ist, steht gleich am Anfang der Arbeit: Wie viel eine Feuerwehr im Ernstfall ausrichtet, hängt an der Zeit bis zum Eintreffen. Für Wohnungsbrände ist der Zusammenhang zwischen dieser Hilfsfrist und der Zahl der Todesopfer nachgewiesen. Diese Zeit entscheidet sich aber nicht im Einsatz, sondern vorher — bei der Frage, wo eine Wache steht und wie viele Kräfte dort bereitstehen.

Die Arbeit sagt dabei ausdrücklich *nicht* vorher, wann und wo ein konkreter Brand ausbricht. Das ginge aus Strukturmerkmalen nicht. Vorhergesagt wird das *Niveau*, auf dem sich die Einsatzlast eines Stadtteils bewegt. Und zwar in zwei Hinsichten:

Frage 1: WIE VIELE?

Wie viele Einsätze hat dieser Stadtteil in diesem Monat?

Antwort ist eine Zahl: 0, 1, 2, ... 451

Seacliff, März:	6
Tenderloin, März:	280

Solche Aufgaben heißen **Regression.**

Frage 2: WELCHE ART?

Welche Einsatzart überwiegt in diesem Stadtteil-Monat?

Antwort ist eine von vier Schubladen

Fehlalarm	technische Hilfe
Rettungsdienst	Brand

Solche Aufgaben heißen **Klassifikation.**

Abbildung 1: Die Arbeit beantwortet zwei verschiedene Fragen über denselben Stadtteil. Die eine verlangt eine Zahl, die andere eine Kategorie. Das sind zwei unterschiedliche Aufgabentypen, und sie brauchen unterschiedliche Verfahren und unterschiedliche Bewertungsmaßstäbe. Die Zahlen im Beispiel sind die Stadtteilmittelwerte aus der Arbeit (6,4 bzw. 279,7 Einsätze je Monat, hier gerundet).

Die zentrale Forschungsfrage der Arbeit lautet sinngemäß: Lassen sich Häufigkeit und Art der Feuerwehreinsätze in den Stadtteilen San Franciscos aus sozioökonomischen, kriminalitätsbezogenen und baulichen Merkmalen vorhersagen — und welches der drei untersuchten Verfahren trifft dabei am besten?

Die Daten

Sieben öffentlich zugängliche Quellen wurden zu einer einzigen Tabelle zusammengeführt. Eine Zeile dieser Tabelle ist *ein Stadtteil in einem Monat*.




Abbildung 2: Aus fünf Datenquellen (sieben Einzelbestände) entsteht eine Tabelle mit 4.752 Zeilen. Jede Zeile beschreibt einen Stadtteil in einem Monat durch zwölf Merkmale. Die beiden Fragezeichen sind das, was die Verfahren erraten sollen. Die Beispielwerte in der rechten Box sind zur Veranschaulichung eingesetzt und stammen nicht aus der Arbeit.

Konkret umfasst der Bestand **36 der 41 Stadtteile** San Franciscos über **132 Monate** von Januar 2015 bis Dezember 2025. Die Feuerwehrquelle enthält insgesamt 720.258 Meldungen, davon 371.316 im Analysezeitraum. Die zwölf Merkmale verteilen sich auf drei inhaltliche Gruppen sowie zwei Hilfsgrößen:

GRUPPE	MERKMALE	ANZAHL
sozioökonomisch	Medianeinkommen, Armutsquote, Akademikerquote, Medianmiete, Leerstandsquote	5
kriminitätsbezogen	Kriminalitätsindex (logarithmiert)	1
baulich	Altbauanteil vor 1940, Wohngebäudeanteil, Anteil brandlastreicher Gewerbefläche	3
Größenkontrolle	Wohnbevölkerung (logarithmiert)	1
Saison	zwei Terme, die den Kalendermonat abbilden	2

Quelle: Tabelle 5 der Arbeit. Die Wohnbevölkerung dient als Größenkontrolle — ohne sie würde ein Modell vor allem abbilden, wie viele Menschen in einem Stadtteil wohnen, und nicht, wie dessen Struktur beschaffen ist.

Der Ablauf

Die Arbeit folgt einem etablierten Ablaufplan für Datenprojekte namens **CRISP-DM**. Der Name steht für „branchenübergreifender Standardprozess für Datenanalyse“ und beschreibt sechs Phasen. Die letzte Phase — der produktive Einsatz — entfällt in dieser Arbeit, weil kein Betrieb geplant ist.




Abbildung 3: Der Ablauf der Arbeit in drei Blöcken. Entscheidend ist, dass alle Festlegungen — Ziel, Maßstab, Merkmale, Aufteilung — *vor* dem ersten Rechenlauf getroffen wurden. So kann keine Entscheidung nachträglich an ein gewünschtes Ergebnis angepasst werden.

Ein Punkt in diesem Ablauf verdient besondere Beachtung, weil er später das ganze Ergebnis prägt: **Wie wird geprüft, ob ein Modell wirklich etwas kann?**

Die Arbeit teilt nicht nach Zeit, sondern nach Ort. Sechs der 36 Stadtteile werden komplett zurückgehalten und erst ganz am Ende einmal angeschaut. Die übrigen 30 werden in fünf Gruppen zu je sechs Stadtteilen aufgeteilt; reihum ist eine Gruppe die Prüfgruppe und die anderen vier sind die Übungsgruppe. Das Ganze wird zehnmal mit neu gemischter Zuteilung wiederholt — zusammen 50 Rechenläufe je Verfahren.

Der Grund für die Trennung nach Stadtteilen statt nach Zeit: Ein Modell soll eine Aussage über einen Stadtteil treffen, den es *noch nie gesehen hat*. Würde man nach Zeit trennen, käme jeder Stadtteil sowohl in der Übung als auch in der Prüfung vor — das Modell könnte sein Niveau einfach auswendig lernen. Wie wirksam das wäre, zeigt eine Zahl aus der Arbeit: Allein der Mittelwert eines Stadtteils erklärt 92,5 % der Schwankung. Die Arbeit prüft bewusst die schwerere Aufgabe.

DIE WICHTIGSTE EINSCHRÄNKUNG, GLEICH VORWEG

4.752 Zeilen klingen nach viel. Aber die Merkmale eines Stadtteils ändern sich kaum von Monat zu Monat — drei von ihnen sind über den gesamten Zeitraum konstant. Die Arbeit rechnet deshalb aus, wie viel *unabhängige* Information tatsächlich vorliegt, und kommt auf rund **39 Einheiten statt 4.752**. Das ist der Grund, warum am Ende viele Unterschiede zwischen den Verfahren statistisch nicht absicherbar sind. Diese Grenze zieht die Arbeit selbst und benennt sie als die Grenze, „die alle übrigen bindet“.

TEIL 2

Fachbegriffe, verständlich erklärt

Alle Begriffe, die in den folgenden Teilen vorkommen — je eine Erklärung in einem Satz und ein Beispiel aus dem Feuerwehr-Zusammenhang dieser Arbeit. Im weiteren Text sind Fachbegriffe beim ersten Auftreten *kursiv* gesetzt und führen als Link hierher zurück.

Die Aufgabe

Merkmal (englisch: Feature)

Eine Information über das, worum es geht — eine Spalte in der Tabelle.

HIER: Die Armutsquote eines Stadtteils ist ein Merkmal. Die Arbeit verwendet zwölf davon.

Zielgröße

Das, was vorhergesagt werden soll — die Spalte, die das Modell erraten muss.

HIER: Die Zahl der Einsätze und die überwiegende Einsatzart.

Regression

Eine Aufgabe, bei der eine *Zahl* herauskommen soll.

HIER: „Wie viele Einsätze?“ → 87. Bei einer Regression kann man fragen, um wie viel man danebenlag.

Klassifikation

Eine Aufgabe, bei der eine *Kategorie* herauskommen soll — eine von mehreren Schubladen.

HIER: „Welche Einsatzart überwiegt?“ → Fehllalarm. Hier gibt es kein „knapp daneben“: entweder richtig oder falsch.

Zählgröße

Eine Zahl, die durch Abzählen entsteht: 0, 1, 2, 3 ... nie negativ, nie halb.

HIER: Einsätze je Monat. Es gibt keine minus drei Einsätze — ein Verfahren, das so etwas vorhersagt, hat ein Problem.

Exposition / Offset

Eine Bezugsgröße, die man vorab herausrechnet, weil sie das Ergebnis trivialerweise größer macht.

HIER: Ein Stadtteil mit 40.000 Einwohnern hat mehr Einsätze als einer mit 4.000 — das ist kein Befund. Interessant ist die Zahl *je Einwohner*. Die Einwohnerzahl wird deshalb als Exposition mitgeführt.

Wie ein Modell lernt und geprüft wird

Trainingsdaten und Testdaten

Die Übungsaufgaben und die Klausur. Auf den Trainingsdaten sucht sich das Modell seine Regeln; auf den Testdaten wird gemessen, ob sie taugen.

HIER: 24 Stadtteile zum Üben, 6 zum Prüfen — und zwar *ganze* Stadtteile, damit das Modell keinen davon schon kennt.

Kreuzvalidierung

Man macht die Klausur nicht einmal, sondern reihum mit wechselnden Prüfgruppen, und mittelt die Ergebnisse.

HIER: Fünf Gruppen zu je sechs Stadtteilen, jede einmal Prüfgruppe; das Ganze zehnmal neu gemischt — 50 Läufe je Verfahren.

Hold-out / Schlussbewertung

Ein Datenteil, der während der gesamten Entwicklung *ungeöffnet* bleibt und ganz am Ende genau einmal geöffnet wird.

HIER: Sechs Stadtteile. Sie dienen als letzte Probe — man kann nichts mehr nachbessern, ohne zu schummeln.

Baseline (Vergleichsmaßstab)

Ein bewusst einfaches Modell, das die gleiche Aufgabe löst. Wer aufwendiger rechnet, muss es schlagen — sonst hat der Aufwand nichts gebracht.

HIER: Zwei Stufen. Stufe 1 ist stumpf („immer den Durchschnitt sagen“), Stufe 2 ist ein schlichtes statistisches Modell. Maßgeblich ist Stufe 2.

Overfitting (Überanpassung)

Ein Modell lernt die Übungsaufgaben auswendig, samt aller Zufälle darin — und versagt bei neuen Aufgaben.

HIER: XGBoost erreicht auf den Übungsdaten ein Bestimmtheitsmaß von 0,975, auf neuen Stadtteilen nur 0,486. Genau diese Lücke ist Überanpassung.

Underfitting (Unteranpassung)

Das Gegenteil: Das Modell ist zu starr und liegt schon bei den Übungsaufgaben daneben.

Verzerrung und Streuung (Bias und Varianz)

Zwei Fehlerarten. Verzerrung heißt: das Modell zielt systematisch daneben. Streuung heißt: es zielt mal so, mal so.

HIER: Wie bei einer Dartscheibe — alle Pfeile dicht beieinander, aber links unten (Verzerrung), oder rund um die Mitte verstreut (Streuung). Beide zusammen ergeben den Gesamtfehler, und sie lassen sich nicht gleichzeitig beliebig klein machen.

Regularisierung

Eine eingebaute Bremse, die ein Modell daran hindert, zu wild auf die Übungsdaten zu reagieren.

HIER: Die Ridge Regression darf ihre Stellschrauben nicht beliebig weit aufdrehen — große Werte kosten sie Punkte.

Hyperparameter

Einstellungen, die man *vorher* festlegen muss, weil das Modell sie nicht selbst aus den Daten lernen kann.

HIER: „Wie viele Bäume?“, „wie tief?“, „wie stark bremsen?“. Die Arbeit probiert je Verfahren 100 zufällige Kombinationen aus. Die beiden Baselines haben keine einzige solche Einstellung — das ist Absicht.

Verlustfunktion

Die Rechenvorschrift, die dem Modell sagt, wie schlimm ein bestimmter Fehler ist. Das Modell sucht die Einstellung, bei der dieser Wert am kleinsten ist.

HIER: Wenn große Ausreißer besonders wehtun sollen, quadriert man die Abweichungen — dann zählt ein Fehler von 10 nicht doppelt, sondern vierfach gegenüber einem Fehler von 5.

Koeffizient

Eine Zahl, die angibt, wie stark ein Merkmal ins Gewicht fällt — das Gewicht auf einer Stellschraube.

HIER: Ein positiver Koeffizient bei der Armutsquote heißt: höhere Armut, mehr erwartete Einsätze.

Wie Ergebnisse abgesichert werden

p-Wert und Signifikanz

Der p-Wert beantwortet: „Wenn zwischen den beiden Verfahren in Wahrheit gar kein Unterschied bestünde — wie oft würde der Zufall allein einen so großen Unterschied hervorbringen?“ Ist das selten (üblich: unter 5 %, also $p < 0,05$), nennt man das Ergebnis *signifikant*.

HIER: Ridge liegt vor XGBoost mit $p = 0,012$ — das ist absicherbar. Ridge liegt vor der Baseline mit $p = 0,275$ — das ist es nicht.

Was „nicht signifikant“ *nicht* heißt

Es heißt nicht „die beiden sind gleich gut“. Es heißt nur: Mit diesen Daten lässt sich ein Unterschied nicht nachweisen. Das kann auch daran liegen, dass zu wenige unabhängige Daten vorliegen.

HIER: Genau das ist der Fall — bei rund 39 unabhängigen Einheiten erkennt der verwendete Test Unterschiede mittlerer Größe nur in 11 bis 40 % der Fälle. Die Arbeit rechnet das eigens nach.

Konfidenzintervall

Ein Bereich statt einer einzelnen Zahl: „der wahre Wert liegt plausibel irgendwo hier drin“. Enthält der Bereich die Null, ist auch „gar kein Unterschied“ plausibel.

HIER: Ridge gegen die Baseline: +2,06 mit Bereich von -0,76 bis +4,88. Die Null liegt drin — also ist auch denkbar, dass Ridge gar nicht besser ist.

Effektstärke

Wie groß ein Unterschied ist, gemessen in Vielfachen der üblichen Schwankung. Ein großer Unterschied in einem ruhigen Feld fällt auf; derselbe Unterschied in einem unruhigen Feld geht unter.

Die Bewertungsmaße dieser Arbeit

RMSE (Wurzel des mittleren quadratischen Fehlers)

Der typische Abstand zwischen Vorhersage und Wirklichkeit, wobei große Ausreißer besonders schwer wiegen. **Kleiner ist besser.**

HIER: RMSE 30 heißt grob: Die Vorhersage liegt typischerweise um etwa 30 Einsätze daneben. Die Einheit ist dieselbe wie bei der Zielgröße — Einsätze.

MAE (mittlerer absoluter Fehler)

Der durchschnittliche Abstand, ohne Extra-Bestrafung für Ausreißer. **Kleiner ist besser.**

HIER: MAE 20 heißt: im Schnitt 20 Einsätze daneben. Der MAE ist immer kleiner als der RMSE; ist der Abstand groß, gibt es einzelne heftige Fehlschläge.

R² (Bestimmtheitsmaß)

Wie viel der tatsächlichen Schwankung das Modell erklärt. 1,0 wäre perfekt, 0 wäre so gut wie „immer den Durchschnitt sagen“. **Größer ist besser — und negativ ist möglich:** dann ist das Modell schlechter als der Durchschnitt.

HIER: Der Gesamtmittelwert erreicht -0,865 — ein Durchschnitt über *alle* Stadtteile ist für einen einzelnen Stadtteil schlechter als nutzlos.

Macro-F1

Ein Maß für Klassifikation, das *jede Kategorie gleich schwer* wiegt — auch die seltene. 1,0 wäre perfekt. **Größer ist besser.**

HIER: Unverzichtbar, weil 79,6 % aller Stadtteil-Monate von Fehlalarmen dominiert werden. Wer stur „Fehlalarm“ sagt, läge in 79,5 % der Fälle richtig — und hätte nichts gelernt. Beim Macro-F1 bekäme er nur 0,221.

Macro-AUROC

Misst, ob das Modell die richtige *Rangfolge* trifft — ob es bei einem echten Brandmonat wenigstens eine höhere Brandwahrscheinlichkeit ausgibt als bei einem anderen. 0,5 wäre Münzwurf, 1,0 perfekt.

HIER: Ein Modell kann die Klassen gut trennen und sie trotzdem falsch zuordnen — genau das passiert in der Arbeit auf den sechs zurückgehaltenen Stadtteilen.

Accuracy (Trefferquote)

Der schlichte Anteil richtiger Zuordnungen. In dieser Arbeit nur mitgeführt, nicht maßgeblich — aus dem beim Macro-F1 genannten Grund.

Zwei Begriffe für den Schluss

Attribution

Die Frage: Worauf achtet ein fertiges Modell am meisten?

HIER: Das Verfahren dafür heißt SHAP und verteilt jede einzelne Vorhersage auf die beteiligten Merkmale.

Ablation

Die andere Frage: Was passiert, wenn man eine Merkmalsgruppe komplett weglässt und neu rechnet?

HIER: Beide Fragen können gegensätzliche Antworten geben — und in dieser Arbeit tun sie es. Worauf ein Modell schaut, ist nicht dasselbe wie das, was es braucht.

TEIL 3

Wie die fünf Verfahren funktionieren

Fünf Verfahren treten an, und sie sind nicht gleichberechtigt. Drei davon werden untersucht (Ridge Regression, Random Forest, XGBoost), zwei sind der Maßstab, an dem sie sich messen lassen müssen (Poisson-GLM und multinomiales Logit). Die Logik dahinter ist streng: **Wenn ein aufwendiges Verfahren die Aufgabe nicht besser löst als ein schlichtes, rechtfertigt es seinen Aufwand nicht.**

Nicht jedes Verfahren tritt bei jeder Frage an. Bei der Frage nach der *Anzahl* laufen alle drei untersuchten Verfahren gegen das Poisson-Modell. Bei der Frage nach der *Art* treten nur Random Forest und XGBoost gegen das Logit an — die Ridge Regression kann keine Kategorien vorhersagen, sondern nur Zahlen, und fällt dort aus.

1. Ridge Regression


DIE GRUNDIDEE

Stellen Sie sich ein Mischpult mit zwölf Reglern vor — einer je *Merkmal*. Wie weit jeder Regler aufgedreht wird, bestimmt, wie stark dieses Merkmal in die Vorhersage eingeht. Das Gerät sucht die Reglerstellung, bei der die Vorhersage im Schnitt am wenigsten danebenliegt. Das ist eine ganz gewöhnliche lineare Rechnung: alle Merkmale werden gewichtet und aufaddiert.

Das Besondere an Ridge ist eine **Bremse**. Wenn zwei Regler das Gleiche bewirken — etwa weil Medianeinkommen und Medianmiete fast dasselbe messen —, kann die gewöhnliche Rechnung den einen weit nach oben und den anderen weit nach unten drehen und trotzdem dasselbe Ergebnis liefern. Solche Einstellungen sind extrem wacklig: Eine kleine Änderung in den Daten kippt sie komplett. Ridge verlangt deshalb für jede Reglerbewegung einen Aufpreis. Weit aufgedrehte Regler kosten Punkte, und deshalb bleiben alle Regler nah an der Null, wenn es nicht zwingende Gründe gibt. Das nennt man *Regularisierung*.

OHNE BREMSE


Regler schlagen wild aus, gleichen sich gegenseitig aus



kippt bei kleinsten Datenänderungen

MIT BREMSE (RIDGE)

jeder Ausschlag kostet — alle bleiben nah an null



bleibt stabil, auch bei ähnlichen Merkmalen

Abbildung 4: Jeder Balken ist ein Regler für ein Merkmal; die waagerechte Linie ist die Nullstellung. Links die gewöhnliche Rechnung, rechts Ridge. Ridge verzichtet auf ein winziges Stück Genauigkeit bei den Übungsdaten und bekommt dafür deutlich ruhigere Vorhersagen bei neuen Daten.

WARUM DAS HIER SINNVOLL IST

Die Merkmale dieser Arbeit beschreiben einander stärker als sie die Zielgröße beschreiben. Der größte Zusammenhang in der Merkmalstabelle liegt bei 0,921 zwischen Medianeinkommen und Medianmiete — das sind fast Zwillinge. Genau in dieser Lage wird die gewöhnliche Rechnung instabil, und genau dafür ist Ridge gebaut.

2. Random Forest

DIE GRUNDIDEE

Ein **Entscheidungsbaum** ist eine Kette von Ja/Nein-Fragen: „Liegt die Armutsquote über 0,15? Wenn ja: Liegt der Altbauanteil über 0,6? Wenn ja: sage 120 Einsätze vorher.“ Ein einzelner Baum ist gut darin, Zusammenspiele zwischen Merkmalen zu finden, aber er ist launisch: Ein paar andere Übungsdaten, und er stellt völlig andere Fragen.

Der Random Forest löst das wie ein Publikumsjoker. Er baut nicht einen Baum, sondern hunderte — jeden auf einer zufällig gezogenen Teilmenge der Übungsdaten und jeden mit einer zufällig eingeschränkten Auswahl an Merkmalen je Frage. Dadurch werden die Bäume *unterschiedlich*. Am Ende wird gemittelt. Einzelne Irrtümer gleichen sich dabei aus, und was übrig bleibt, ist deutlich stabiler als jeder Baum für sich.

VIELE BÄUME, GLEICHZEITIG GEWACHSEN — JEDER SIEHT ANDERE DATEN




Abbildung 5: Jeder Baum ist für sich unzuverlässig, aber die Fehler zeigen in verschiedene Richtungen und heben sich beim Mitteln weitgehend auf. Die Zahlen sind ein erfundenes Beispiel zur Veranschaulichung des Prinzips.

WARUM DAS HIER SINNVOLL IST

Bäume finden Zusammenspiele von selbst. Ein lineares Modell rechnet jedes Merkmal einzeln dazu; wenn Armut nur *in Kombination mit* Altbaubestand wirkt, muss man ihm das ausdrücklich sagen — wer es nicht vorab vermutet, findet es auch nicht. Ein Baum findet solche Kombinationen, ohne dass man sie vorher kennen muss. Das ist der Vorsprung, den die Baumverfahren in dieser Arbeit haben könnten. Ob sie ihn hier tatsächlich haben, ist genau die empirische Frage der Arbeit.

3. XGBoost

DIE GRUNDIDEE

XGBoost verwendet ebenfalls Bäume, aber baut sie in umgekehrter Logik. Beim Random Forest wachsen alle Bäume gleichzeitig und unabhängig. Bei XGBoost wachsen sie **nacheinander**, und jeder neue Baum bekommt eine andere Aufgabe: Er soll nicht die Einsätze vorhersagen, sondern genau das, was die bisherigen Bäume noch falsch hatten. Das ist ein schrittweises Nachbessern und heißt *Boosting*.

Ein Vergleich: Der Random Forest ist eine Jury, die unabhängig voneinander schätzt und dann mittelt. XGBoost ist ein Team, bei dem jeder Nachfolger die Notizen des Vorgängers liest und nur dessen Restfehler bearbeitet.

Dieses Verfahren neigt naturgemäß zum Auswendiglernen — irgendwann korrigiert es nur noch Zufälle in den Übungsdaten. Deshalb hat auch XGBoost eine *Bremse*: Jeder neue Baum darf nur einen kleinen Teil seiner Korrektur beisteuern, und zu verzweigte Bäume kosten Strafpunkte.

EIN BAUM NACH DEM ANDEREN — JEDER BEARBEITET NUR DEN RESTFEHLER




Abbildung 6: Der Restfehler schrumpft mit jedem weiteren Baum. Der Reiz des Verfahrens ist auch seine Gefahr: Ohne Bremse schrumpft der Fehler bei den Übungsdaten weiter, während er bei neuen Daten schon wieder wächst. Die Balkenhöhen stellen das Prinzip dar und sind keine gemessenen Werte.

WARUM DAS HIER SINNVOLL IST

XGBoost gilt in der Fachliteratur als das stärkste Verfahren für Daten in Tabellenform — also genau für die Art von Daten, um die es hier geht. Die Arbeit zitiert mehrere Vergleichsstudien mit diesem Befund. Es ist damit der natürliche Herausforderer.

4. Poisson-GLM — die Baseline für die Anzahl


DIE GRUNDIDEE

Dieses Modell nimmt eine Sache ernst, die die anderen drei Verfahren nicht wissen: Die Zielgröße ist eine *Zählgröße*. Man kann keine minus fünf Einsätze haben, und bei Zählungen hängen Höhe und Schwankung zusammen — wo im Schnitt 200 Einsätze passieren, schwankt es stärker als dort, wo es zehn sind.

Die Denkweise des Modells ist **multiplikativ**: Es schätzt nicht direkt die Zahl der Einsätze, sondern das *Risiko pro Einwohner*, und multipliziert das anschließend mit der Einwohnerzahl. Die Merkmale wirken dabei

als Faktoren, nicht als Summanden — ein Merkmal erhöht die erwartete Zahl also um einen bestimmten Prozentsatz und nicht um eine feste Anzahl.

DIE GRÖSSE WIRD HERAUSGERECHNET, BEVOR DIE STRUKTUR BEURTEILT WIRD



Das Modell multipliziert, statt zu addieren. Deshalb kann nie eine negative Zahl herauskommen — anders als bei einer geraden Linie.

Abbildung 7: Das Poisson-Modell mit Exposition. Es trennt sauber, was ein Stadtteil an Einsätzen allein deshalb hat, weil dort viele Menschen wohnen, von dem, was seine Struktur hervorbringt.

WARUM DAS ALS MASSSTAB DIENT

Genau weil es so schlicht ist. Es hat **keinen einzigen einstellbaren Hyperparameter** — man kann bei ihm nichts optimieren, nichts glücklich treffen und nichts versehentlich gut einstellen. Es liefert jedes Mal dasselbe Ergebnis. Das macht es zu einer ehrlichen Messlatte: Wer es nicht schlägt, hat mit all seinen Einstellungen und Rechenstunden nichts gewonnen. Die Arbeit lässt es zudem über genau dieselben 50 Durchläufe und dieselben zwölf Merkmale laufen wie die Herausforderer — es ist ein vollwertiger Mitbewerber, kein bequemer Strohhalm.

5. Multinomiales Logit — die Baseline für die Einsatzart

DIE GRUNDIDEE

Bei der Frage nach der Einsatzart gibt es vier mögliche Antworten. Das Modell gibt deshalb nicht eine Antwort aus, sondern vier Wahrscheinlichkeiten, die sich zu 100 % addieren. Vorhergesagt wird die Kategorie mit dem höchsten Wert.

Technisch funktioniert es über **Chancenverhältnisse**: Eine Kategorie wird als Bezugspunkt gewählt, und für jede der übrigen wird geschätzt, um welchen Faktor sie gegenüber diesem Bezugspunkt wahrscheinlicher oder unwahrscheinlicher wird, wenn sich ein Merkmal ändert. Aus diesen Verhältnissen lassen sich alle vier Wahrscheinlichkeiten zurückrechnen.



Abbildung 8: Das Logit-Modell verteilt 100 % auf die vier Einsatzarten. Die Prozentwerte im Bild sind erfunden und dienen nur der Darstellung des Prinzips.

WARUM DAS ALS MASSSTAB DIENT

Aus demselben Grund wie beim Poisson-Modell: Es hat keine einstellbaren Schrauben und ist damit reproduzierbar und unbestechlich. Ein zusätzlicher Kniff der Arbeit: Weil Fehlalarme 79,6 % aller Fälle ausmachen und Brände nur 1,5 %, würde das Modell sonst einfach immer „Fehlalarm“ sagen. Es bekommt deshalb *ausgeglichene Klassengewichte*: Ein seltener Brandmonat zählt beim Lernen entsprechend schwerer. Die Daten selbst werden dabei nicht verändert — keine Zeile wird verdoppelt oder entfernt.

TEIL 4

Die Formeln, Stück für Stück

Formeln sind abgekürzte Sätze. Dieser Teil schreibt sie wieder aus. Verständlichkeit geht dabei vor mathematischer Vollständigkeit — wo bewusst vereinfacht wurde, steht es dabei.

VIER ZEICHEN, DIE ÜBERALL VORKOMMEN

Σ (griechisches Sigma) heißt schlicht „*addiere alles zusammen*“. Unter dem Zeichen steht, wo man anfängt, darüber, wo man aufhört. „ Σ über alle Zeilen“ heißt: gehe jede Zeile der Tabelle durch und zähle die Werte zusammen.

Ein Dach über einem Buchstaben (β , $\hat{y}$) bedeutet *geschätzt* — das ist nicht der wahre Wert, sondern der, den das Modell aus den Daten gewonnen hat.

Fette Buchstaben ($\mathbf{x}$, $\boldsymbol{\beta}$) sind keine einzelne Zahl, sondern eine ganze Liste von Zahlen — hier meist eine Liste mit zwölf Einträgen, einem je Merkmal.

„**arg min**“ heißt: *diejenige Einstellung, bei der der folgende Ausdruck am kleinsten wird*. Es ist die mathematische Form von „suche das Beste“.

Die gemeinsame Grundform der beiden Baselines

Beide Baselines gehören zur selben Modellfamilie, den *verallgemeinerten linearen Modellen*. Ihre allgemeine Form ist Formel 1 der Arbeit:

$$g(\mathbb{E}[y \mid \mathbf{x}]) = \mathbf{x}^T \boldsymbol{\beta}$$

Formel 1 der Arbeit · allgemeine Form eines verallgemeinerten linearen Modells

$\mathbb{E}[y \mid \mathbf{x}]$ Der **Erwartungswert**: Was kommt im Schnitt heraus, wenn ein Stadtteil-Monat die Merkmale $\mathbf{x}$ hat? Der senkrechte Strich heißt „gegeben, dass“. Also: der erwartete Wert, gegeben diese Merkmale.

$\mathbf{x}^T \boldsymbol{\beta}$ Die **gewichtete Summe**: Nimm jedes Merkmal, multipliziere es mit seinem *Koeffizienten*, und addiere alles. Ausgeschrieben: $\beta_1 \cdot \text{Armutsquote} + \beta_2 \cdot \text{Altbauanteil} + \dots$ Das kleine hochgestellte Zeichen bedeutet nur, dass die beiden Listen paarweise multipliziert werden.

$g(\dots)$ Die **Verbindungsfunktion**. Sie ist der ganze Trick dieser Modellfamilie: Die gewichtete Summe kann jeden Wert annehmen, auch negative. Eine Einsatzzahl darf aber nicht negativ sein und eine Wahrscheinlichkeit muss zwischen 0 und 1 liegen. g rechnet zwischen beiden Welten um.

Formel 1 · Poisson-GLM mit Exposition

$$\log(\mu) = \log(B) + \mathbf{x}^T \boldsymbol{\beta}$$

Formel 2 der Arbeit · Baseline für die Einsatzhäufigkeit

- μ** Die **erwartete Zahl der Einsätze** in diesem Stadtteil-Monat — das, was gesucht wird.
- log** Der **Logarithmus**. Hier reicht eine einzige Eigenschaft davon: Was auf der Logarithmus-Seite addiert wird, wird auf der normalen Seite *multipliziert*. Deshalb ist dieses Modell multiplikativ, so wie es Abbildung 7 gezeigt hat.
- B** Die **Wohnbevölkerung** des Stadtteils, die *Exposition*.
- log(B)** Steht **ohne eigenen Koeffizienten** da — oder genauer: mit einem fest auf eins gesetzten. Das Modell darf hier nichts justieren. Genau das macht aus einer Aussage über Häufigkeiten eine Aussage über Raten, ohne dass dafür ein Freiheitsgrad verbraucht wird. Ein solcher fest vorgegebener Term heißt *Offset*.

Ausgeschrieben lautet die Formel: *Die erwartete Einsatzzahl ist die Einwohnerzahl, multipliziert mit einem Risikofaktor, der sich aus den Merkmalen des Stadtteils ergibt.*

Formel 2 · Multinomiales Logit

$$\log \frac{\Pr(y = k \mid \mathbf{x})}{\Pr(y = K \mid \mathbf{x})} = \mathbf{x}^\top \boldsymbol{\beta}_k$$

Formel 3 der Arbeit · Baseline für die Einsatzart

- Pr(...)** Eine **Wahrscheinlichkeit**, also eine Zahl zwischen 0 und 1.
- k** Eine der Einsatzarten, zum Beispiel „Brand“.
- K** Die **Bezugskategorie**, mit der alle anderen verglichen werden. Welche das ist, ist reine Konvention und ändert am Ergebnis nichts.
- der Bruch** Das **Chancenverhältnis**: Wie viel mal wahrscheinlicher ist „Brand“ als die Bezugskategorie? Steht dort 2, ist Brand doppelt so wahrscheinlich.
- $\boldsymbol{\beta}_k$** Jede Kategorie hat ihren **eigenen Satz Koeffizienten**. Bei vier Kategorien werden drei solche Sätze geschätzt; der vierte ergibt sich daraus, weil sich alle Wahrscheinlichkeiten zu eins addieren müssen.

Formel 3 · Ridge Regression

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta}} \{ \sum_i (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 + \lambda \sum_j \beta_j^2 \}$$

Formel 4 der Arbeit · Zielfunktion der Ridge Regression

Diese Formel ist der Kern des ganzen Verfahrens, und sie besteht aus genau zwei Bestandteilen, die miteinander im Streit liegen.

- y_i** Die **wirklich beobachtete** Einsatzzahl in Zeile i.
- $\mathbf{x}_i^\top \boldsymbol{\beta}$** Die **vorhergesagte** Einsatzzahl für dieselbe Zeile.
- $(\dots)^2$** Die Differenz wird **quadriert**. Zwei Gründe: Erstens verschwindet damit das Vorzeichen — zu hoch und zu niedrig sind gleich schlimm. Zweitens wiegen große Fehler überproportional schwer: 20 danebenzuliegen ist nicht doppelt, sondern viermal so teuer wie 10.

- Σ_i Summiert über **alle Zeilen** der Trainingsdaten. Dieser erste Block ist die klassische *Verlustfunktion*: Wie schlecht passt das Modell?
- $\lambda \Sigma_j \beta_j^2$ Der **Strafterm** — der zweite Block, und alles, was Ridge von der gewöhnlichen Rechnung unterscheidet. Summiert wird hier über die *Koeffizienten*, nicht über die Zeilen. Jeder Regler, der weit von null entfernt steht, erhöht den Wert und macht die Lösung damit schlechter.
- λ Das **Strafgewicht** (griechisch: Lambda): wie hart die Bremse zieht. Bei $\lambda = 0$ verschwindet der Strafterm, und man hat wieder die gewöhnliche Rechnung. Je größer λ , desto näher rücken alle Koeffizienten an null. λ ist der einzige *Hyperparameter* der Ridge Regression — und damit genau der eine Parameter, den die Baseline nicht kennt.

Ausgeschrieben: *Suche die Reglerstellung, bei der die Summe aus zwei Übeln am kleinsten ist — wie sehr man danebenliegt, und wie weit man die Regler dafür aufreißen musste.*

Die Arbeit gibt zusätzlich die geschlossene Lösung an (Formel 5). Sie besagt, dass man das Ergebnis direkt ausrechnen kann und nichts ausprobieren muss:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

Formel 5 der Arbeit · geschlossene Lösung

Bewusst vereinfacht: Die Einzelheiten dieser Formel sind Matrizenrechnung und werden hier nicht auseinandergenommen. Eine Sache lohnt aber: Das hochgestellte -1 steht für eine Umkehroperation, ähnlich dem Teilen bei gewöhnlichen Zahlen. Und wie man durch null nicht teilen kann, kann diese Umkehrung scheitern — genau dann, wenn zwei Merkmale zu ähnlich sind. Das λ addiert einen kleinen positiven Wert an der entscheidenden Stelle und macht die Rechnung dadurch wieder durchführbar. Der Strafterm ist also nicht nur eine Bremse gegen *Overfitting*, sondern hält die Rechnung überhaupt erst am Leben.

Formel 4 · XGBoost

$$\mathcal{L} = \Sigma_i l(y_i, \hat{y}_i) + \Sigma_r \Omega(f_r)$$

Formel 6 der Arbeit · regularisierte Zielfunktion des Gradient Boosting

- $\mathcal{L}$ Die **Gesamtzielgröße**, die XGBoost so klein wie möglich machen will.
- $l(y, \hat{y})$ Die **Verlustfunktion** für eine einzelne Zeile: Wie weit lag die Vorhersage $\hat{y}$ von der Wirklichkeit y entfernt?
- Σ_i Summiert über alle Zeilen — der gesamte Anpassungsfehler.
- f_r Der **r-te Baum** des Modells.
- $\Omega(f_r)$ Der **Strafterm für die Komplexität** dieses Baums — er wächst mit der Zahl der Endknoten und der Größe der dort abgelegten Werte. Je verzweigter ein Baum, desto teurer.
- Σ_r Summiert über **alle Bäume**.

Die Ähnlichkeit zur Ridge-Formel ist kein Zufall, und sie ist der wichtigste Punkt dieses Abschnitts: **Beide Formeln haben denselben Bauplan** — links steht, wie schlecht das Modell passt, rechts steht, was seine Flexibilität kosten soll. Nur der Preis wird verschieden berechnet: Ridge bestraft große Regler, XGBoost bestraft verzweigte Bäume. Dieselbe Idee, zweimal.

Formel 5 · Random Forest

HIER GIBT ES KEINE FORMEL — UND DAS IST RICHTIG SO

Die Arbeit führt im Formelverzeichnis acht Formeln auf; für den Random Forest ist keine darunter. Das ist kein Versäumnis: Das Verfahren lässt sich nicht in einer Gleichung hinschreiben. Ein Baum besteht aus Ja/Nein-Fragen, nicht aus einer Rechenvorschrift. Was sich angeben lässt, ist der letzte Schritt: Alle Bäume sagen etwas vorher, und ihre Vorhersagen werden gemittelt — bei einer Zahl der Durchschnitt, bei einer Kategorie die Mehrheit. Genau das zeigt Abbildung 5.

Die Arbeit nennt dafür allerdings ein wichtiges Ergebnis aus der Literatur: Der Fehler eines solchen Waldes hängt von zwei Dingen ab — wie treffsicher die einzelnen Bäume sind und wie stark sie einander ähneln. Deshalb wird jedem Baum an jedem Verzweigungspunkt nur eine zufällige Auswahl der Merkmale angeboten: Das macht ihn für sich genommen etwas schlechter, aber unähnlicher zu den anderen — und der Wald als Ganzes wird besser.

Formel 6 · Das Macro-F1-Maß

$$F1_k = \frac{2 \cdot P_k \cdot R_k}{P_k + R_k} \quad \text{Macro-F1} = \frac{1}{K} \sum_k F1_k$$

Formel 7 der Arbeit · klassenweises F1-Maß und Macro-F1

P_k **Präzision:** Von allen Monaten, die das Modell als „Brand“ bezeichnet hat — wie viele waren es wirklich? (Wie oft hat es sich nicht blamiert, wenn es Alarm schlug?)

R_k **Trefferquote:** Von allen Monaten, die wirklich Brandmonate waren — wie viele hat das Modell gefunden? (Wie viel hat es übersehen?)

$F1_k$ Beide zusammen, als **harmonisches Mittel**. Anders als ein gewöhnlicher Durchschnitt fällt dieses Mittel niedrig aus, sobald auch nur einer der beiden Werte niedrig ist. Beide Werte müssen gut sein — einer allein reicht nicht.

K Die Zahl der Kategorien, hier vier.

$(1/K) \sum_k$ Der **ungewichtete Durchschnitt** über alle vier Kategorien — darin steckt das Wort „Macro“. Die seltene Kategorie „Brand“ zählt genauso viel wie die häufige Kategorie „Fehlalarm“, obwohl sie fünfzigmal seltener vorkommt.

Diese letzte Zeile hat für die Ergebnisse dieser Arbeit spürbare Folgen, und sie wird in Teil 5 wieder auftauchen: Weil „Brand“ ein volles Viertel des Gesamtwerts ausmacht, obwohl es kaum vorkommt, hängt ein Viertel des Leitmaßes an sehr wenigen Fällen.

Warum das trotzdem die richtige Wahl ist: Ein Maß, das jede Kategorie nach ihrer Häufigkeit gewichtet, würde die Brände praktisch ignorieren — und die Brände sind der Grund, warum es eine Feuerwehr gibt.

TEIL 5

Bewertung und Ergebnisse

Jetzt die Zahlen. Alle Werte in diesem Teil stammen unverändert aus den Ergebnistabellen der Arbeit und den Ergebnisdateien im Projektordner; nichts ist gerundet, geschätzt oder ergänzt.

Womit gemessen wird

Für die beiden Fragen gelten verschiedene Maße, weil eine Zahl anders danebenliegen kann als eine Kategorie.

MASS	WOFÜR	WAS DIE ZAHL BEDEUTET	BESSER IST
RMSE	Anzahl	typischer Abstand zur Wirklichkeit, in Einsätzen; große Ausreißer wiegen extra schwer	kleiner
MAE	Anzahl	durchschnittlicher Abstand, in Einsätzen, ohne Extra-Strafe	kleiner
R²	Anzahl	Anteil der erklärten Schwankung; 0 = so gut wie der Durchschnitt	größer
Macro-F1	Einsatzart	Trefferqualität, jede der vier Arten gleich gewichtet	größer
Macro-AUROC	Einsatzart	ob die Rangfolge der Wahrscheinlichkeiten stimmt; 0,5 = Münzwurf	größer

Hauptmaße sind laut Arbeit der RMSE bei der Anzahl und das Macro-F1 bei der Einsatzart; die übrigen laufen ergänzend mit. Die Accuracy wird nur mitgeführt und ist nicht maßgeblich.

ZWEI AUSWERTUNGEN, NICHT EINE

Jedes Ergebnis liegt in zwei Fassungen vor, und beide werden berichtet:

Kreuzvalidierung — 50 Durchläufe auf 30 Stadtteilen, jeweils mit wechselnden Prüfgruppen. Das ist der belastbare Wert, weil er gemittelt ist und eine Streuung hat.

Schlussbewertung — eine einzige Messung auf den sechs zurückgehaltenen Stadtteilen. Ohne Streuung, ohne Test. Die Arbeit hält ausdrücklich fest, dass diese sechs Stadtteile kein verkleinertes Abbild der Stadt sind: Auf sie entfallen 4,67 % branddominierte Monate gegenüber 0,83 % bei den übrigen. Sie sind eine Probe unter erschwerten Bedingungen, kein Durchschnitt.

Ergebnis 1 · Die Zahl der Einsätze

MODELL	KREUZVALIDIERUNG			SCHLUSSBEWERTUNG		
	RMSE	MAE	R ²	RMSE	MAE	R ²
Poisson-GLM (Baseline)	32,99	21,44	0,607	28,46	20,10	0,625
Ridge Regression	30,93	20,36	0,655	30,30	21,95	0,575
Random Forest	34,96	24,07	0,498	27,46	21,13	0,651
XGBoost	37,39	25,13	0,486	25,83	19,86	0,691
Gesamtmittelwert (Stufe 1)	68,08	50,34	−0,865	49,32	38,70	−0,126

Tabelle 10 der Arbeit. Fett hervorgehoben ist jeweils der beste Wert je Spalte. Man beachte: In der linken Hälfte gewinnt Ridge, in der rechten XGBoost — die Rangfolge dreht sich um.




Abbildung 9: Derselbe Datensatz, zwei Auswertungen, zwei Sieger. Was in beiden Auswertungen gleich bleibt: Alle vier Modelle liegen weit vor dem stumpfen Durchschnitt, und sie liegen alle nah beieinander. Die Balkenlängen entsprechen den RMSE-Werten aus Tabelle 10 der Arbeit.

WAS DAS BEDEUTET

Erstens: Die Merkmale tragen. Der stumpfe Gesamtdurchschnitt kommt auf einen RMSE von 68,08 und ein R² von −0,865 — er ist für einen einzelnen Stadtteil schlechter als nutzlos. Jedes Modell, das die zwölf Merkmale nutzt, halbiert diesen Fehler ungefähr. Ein Stadtteil, den das Modell noch nie gesehen hat, lässt sich also aus seinem Profil einschätzen. Die Arbeit beziffert die praktische Genauigkeit auf einen mittleren absoluten Fehler von rund 20 Einsätzen.

Zweitens — und das ist der eigentliche Befund: Kein untersuchtes Verfahren schlägt die Baseline nachweisbar. Die Arbeit hatte vorab festgelegt, dass ein Verfahren nur dann erfolgreich ist, wenn es die Poisson-Baseline übertrifft. Das Ergebnis:

VERGLEICH	UNTERSCHIED IM RMSE	GEWONNENE LÄUFE	P-WERT
Ridge gegen Baseline	+2,06 [−0,76 bis +4,88]	8 von 10	0,275
Random Forest gegen Baseline	−1,98 [−7,66 bis +3,71]	6 von 10	0,922
XGBoost gegen Baseline	−4,40 [−9,50 bis +0,69]	4 von 10	0,275
Ridge gegen Random Forest	+4,04 [+0,58 bis +7,49]	9 von 10	0,023
Ridge gegen XGBoost	+6,46 [+3,53 bis +9,40]	10 von 10	0,012
Random Forest gegen XGBoost	+2,43 [−0,79 bis +5,64]	7 von 10	0,211

Tabelle 11 der Arbeit. Ein Pluszeichen heißt: das erstgenannte Verfahren ist besser. In eckigen Klammern das *Konfidenzintervall*. Fette p-Werte unter 0,05 sind statistisch absicherbar.

Man liest diese Tabelle so: In den oberen drei Zeilen enthält der Klammerbereich jedes Mal die Null — damit ist auch „gar kein Unterschied“ eine plausible Erklärung. Kein untersuchtes Verfahren hat die Baseline geschlagen. Aber — und das gehört zur Ehrlichkeit dazu — auch keines ist nachweisbar schlechter.

In den unteren drei Zeilen wird das Bild deutlich: **Ridge schlägt beide Baumverfahren**, gegen XGBoost in allen zehn Wiederholungen. Die drei untersuchten Verfahren unterscheiden sich also sehr wohl voneinander — nur eben nicht von der schlichten Baseline. Ausgerechnet das einfachste der drei liegt vorn.


WARUM SICH DIE RANGFOLGE AUF DEN SECHS STADTTTEILEN UMDREHT

In der Kreuzvalidierung gewinnt Ridge, auf den sechs zurückgehaltenen Stadtteilen XGBoost. Die Arbeit erklärt diesen Widerspruch nicht weg, sondern erklärt ihn zum Befund: Die beiden Zahlenreihen sind gar nicht vergleichbar. Links wird fünfzigmal nach Anpassung auf 24 Stadtteilen gemessen, rechts einmal an sechs Einheiten nach Anpassung auf 30 — ohne Streuung und ohne statistischen Test. Welches Verfahren vorn liegt, hängt bei rund 39 unabhängigen Einheiten schlicht daran, welche Stadtteile gerade im Test stehen. Genau dieses Schwan-ken ist das Ergebnis.

Ergebnis 2 · Die Art der Einsätze

Hier ist zuerst wichtig, was überhaupt erreichbar wäre. Die Arbeit misst das *vor* der Modellwahl und kommt auf zwei Obergrenzen. Die eine kommt daher, dass die Zielgröße selbst unscharf ist: Zieht man den Zufall neu, wechselt die überwiegende Einsatzart in 13,6 % der Stadtteil-Monate. Die andere kommt daher, dass sich die Merkmale innerhalb eines Stadtteils kaum bewegen — ein Modell kann im Kern nicht mehr tun, als jedem Stadtteil seine häufigste Art zuzuweisen, und 27 der 30 Stadtteile haben dieselbe.

KREUZVALIDIERUNG · MACRO-F1 (1,0 WÄRE FEHLERFREI)



SCHLUSSEBEWERTUNG · 6 ZURÜCKGEHALTENE STADTTTEILE



Abbildung 10: Obergrenze B ist das Maximum, das mit Merkmalen erreichbar ist, die sich innerhalb eines Stadtteils kaum ändern; Obergrenze A liegt darüber und ergibt sich aus der Unschärfe der Zielgröße selbst. Der gesamte Spielraum für Merkmals- und Verfahrenswahl liegt zwischen der Mehrheitsklasse und Obergrenze B — das sind 0,193 Macro-F1. Werte aus Tabelle 12 der Arbeit.

MODELL	KREUZVALIDIERUNG		SCHLUSSEBEWERTUNG	
	MACRO-F1	AUROC	MACRO-F1	AUROC
Mehrheitsklasse (Stufe 1)	0,221	—	0,222	—
Multinomiales Logit (Baseline)	0,301 ± 0,015	0,725	0,350	0,797
Random Forest	0,318 ± 0,014	0,705	0,282	0,762
XGBoost	0,301 ± 0,015	0,665	0,291	0,818
Obergrenze B	0,415	—	0,423	—
Obergrenze A	0,641	—	0,677	—

Tabelle 12 der Arbeit. Das ±-Zeichen gibt die Streuung über die zehn Wiederholungen an.

WAS DAS BEDEUTET

In der Kreuzvalidierung schlägt der Random Forest die Baseline — um 0,017 Macro-F1, in neun von zehn Wiederholungen, mit $p = 0,004$. Das ist der einzige Vergleich in der gesamten Arbeit, in dem ein untersuchtes Verfahren das vorab gesetzte Erfolgskriterium erfüllt. **XGBoost erreicht mit $-0,0003$ exakt das Niveau der Baseline** ($p = 1,000$).

Gemessen am Erreichbaren bleibt der Vorsprung allerdings klein: Der Random Forest schöpft 50,2 % des Abstands zwischen Mehrheitsklasse und Obergrenze B aus, XGBoost 41,0 %. Bis zur Obergrenze fehlen dem besseren noch 0,096 Macro-F1.

Auf den sechs zurückgehaltenen Stadtteilen kehrt sich auch das um: Dort liegt das schlichte Logit mit 0,350 vor beiden Baumverfahren (0,291 und 0,282). Die Arbeit nennt zwei mögliche Erklärungen — Über-

anpassung der Baumverfahren, oder die andere Klassenverteilung der zurückgehaltenen Stadtteile — und stellt ausdrücklich keine davon als entschieden dar.

EIN ERGEBNIS, DAS MAN KENNEN SOLLTE, BEVOR MAN DIESE ZAHLEN VERWENDET

Das Macro-F1 von 0,318 wird fast vollständig von den beiden häufigen Kategorien getragen. Der Random Forest erreicht im Einzelnen: 0,860 für Fehllalarm, 0,373 für technische Hilfe, **0,040 für Rettungseinsätze und 0,000 für Brände**. Die seltenste Kategorie sagt er in 49 von 50 Läufen kein einziges Mal vorher. Bei XGBoost fällt das Bild ähnlich aus.

Ein Viertel des Leitmaßes ruht damit auf einer Kategorie, die praktisch kein Modell vergibt — ausgerechnet auf den Bränden. Die Arbeit schreibt das so hin, ohne es zu beschönigen.

Ergebnis 3 · Der Rechenaufwand

Hier trennen sich die Verfahren eindeutig, und als einziges Ergebnis der Arbeit nicht um Prozentpunkte, sondern um Größenordnungen.

TRAININGSZEIT FÜR EINEN DURCHLAUF (EINSATZHÄUFIGKEIT)




Abbildung 11: Werte aus Tabelle 14 der Arbeit. Wichtig: Die Arbeit weist darauf hin, dass je Konfiguration nur eine einzelne Messung vorliegt — die Zahlen sind als Größenordnung zu lesen, nicht als exakte Kennzahl. Und im Alltag wäre selbst das langsamste Verfahren schnell genug: Es sagt eine komplette Prüfgruppe in unter einer Zehntelsekunde vorher.

Der größte Posten ist ohnehin nicht das Training selbst, sondern die Suche nach den richtigen Einstellungen davor: 25 Suchläufe mit je 100 Versuchen über vier innere Prüfgruppen ergeben 10.000 Modellanpassungen und rund 137 Minuten reine Suchzeit — davon 36 Sekunden auf Ridge. Der Aufwandsnachteil der Baumverfahren entsteht also nicht erst beim fertigen Modell, sondern vervielfacht sich über die Modellwahl.

Der eigentliche Befund der Arbeit

Die Arbeit macht eine Gegenprobe, die das Gesamtbild erst richtig zusammensetzt. Sie fragt: Was bringt mehr — ein anderes *Verfahren* zu wählen, oder dasselbe schlichte Verfahren anders *anzusetzen*? Dafür wird die Baseline schrittweise flexibler gemacht.

RMSE — DIESELBE AUFGABE, VERSCHIEDENE ANSÄTZE



Die Wahl des **Verfahrens** ändert den Fehler um höchstens **4,4**.
Die Wahl der **Ansatzform** ändert ihn um bis zu **4.170,3** — fast das Tausendfache.

Abbildung 12: Werte aus Abbildung 8 der Arbeit. Die erwartete Wirkung wäre gewesen, dass die Baseline durch mehr Flexibilität besser wird. Das Gegenteil tritt ein — und zwar dramatisch. Die vier obersten Balken sind bei diesem Maßstab kaum noch sichtbar; genau das ist die Aussage.

Der Vergleich ist auf zwei Arten lehrreich. Erstens zeigt er, dass die Baseline nicht etwa deshalb gewinnt, weil sie zu starr wäre und die Verfahren ihr nichts voraushätten — mehr Flexibilität macht sie hier massiv schlechter, nicht besser. Zweitens rückt er die Verfahrensfrage zurecht: Wer bei einer solchen Aufgabe Ergebnisse verbessern will, gewinnt nichts dabei, Ridge gegen XGBoost zu tauschen. Die Arbeit formuliert es so, dass zwischen den drei Verfahren nicht einmal zwei Promille dessen liegen, was zwischen der sparsamsten und der reichhaltigsten Ansatzform liegt.

Welche Merkmale zählen

Zum Schluss noch der inhaltliche Befund — und er enthält eine Überraschung. Die Arbeit stellt zwei Fragen getrennt: Worauf *achtet* ein Modell (*Attribution*)? Und was *fehlt*, wenn man eine Gruppe wegnimmt (*Ablation*)?

MERKMALSGRUPPE	AUFMERKSAMKEIT DES MODELLS	FEHLERÄNDERUNG BEIM WEGLASSEN	IN LÄUFEN
kriminallitätsbezogen	10,7 %	+6,10 deutlich schlechter	10 von 10
sozioökonomisch	41,4 %	−4,95 besser	1 von 10
baulich	34,0 %	−8,04 besser	0 von 10
Größenkontrolle	8,9 %	−5,02 besser	0 von 10
Saison	5,1 %	+0,28	10 von 10

Abbildung 10 und Tabelle 15 der Arbeit, Mengenstrang, Poisson-GLM. Ein Plus bei der Fehleränderung heißt: Ohne diese Gruppe wird die Vorhersage schlechter — die Gruppe wird also gebraucht.

Die beiden Spalten stehen quer zueinander, und das ist der Punkt. Die kriminallitätsbezogene Gruppe besteht aus einem einzigen Merkmal und bekommt die *geringste* Aufmerksamkeit — aber ohne sie wird die Vorhersage in allen zehn Läufen deutlich schlechter. Umgekehrt binden die sozioökonomischen und baulichen Merkmale drei Viertel der Aufmerksamkeit, und die Vorhersage wird *besser*, wenn man sie weglässt.

Die Arbeit erklärt das an drei messbaren Eigenschaften der Daten. Die wichtigste: Der Kriminalitätsindex ist das einzige Merkmal, das sich *von Monat zu Monat bewegt* — er nimmt je Stadtteil im Schnitt 128,1 verschiedene Werte an. Die sozioökonomischen Merkmale haben höchstens vier Werte über elf Jahre, die baulichen genau einen. Sie sind faktisch Konstanten je Stadtteil, und bei nur 24 Trainingsstadtteilen kosten solche redundanten Merkmale mehr an Streuung, als sie an Verzerrung abbauen.

WAS DIESER BEFUND AUSDRÜCKLICH NICHT HEISST

Die Arbeit formuliert das selbst sehr vorsichtig, und das gehört hierher: Belegt ist nicht, dass Kriminalität Feuerwehreinsätze *verursacht*. Die Spalte stammt aus polizeilichen Meldungen und misst neben dem Tatgeschehen auch die Anzeigebereitschaft und die Kontrollintensität der Polizei. Belegt ist nur, dass die registrierte Kriminalitätsbelastung eines Stadtteils der stärkste verfügbare Einzelindikator für seine Einsatzlast ist. Die gesamte Arbeit ist prognoseorientiert und erhebt an keiner Stelle einen Ursachenanspruch.

Die Antwort in drei Sätzen

1. Ja, es funktioniert — im Grundsatz. Aus den Merkmalen eines Stadtteils lässt sich seine Einsatzlast vorher-sagen, auch für einen Stadtteil, den das Modell nie gesehen hat. Der Fehler liegt bei rund 20 Einsätzen im Mittel und damit weit unter dem, was ein Durchschnittswert leisten würde.

2. Aber nicht mit den aufwendigen Verfahren. Bei der Frage nach der Anzahl schlägt keines der drei unter-suchten Verfahren die schlichte Baseline nachweisbar; bei der Frage nach der Art gelingt es einzig dem Random Forest, und nur in einer der beiden Auswertungen. Die Verfahren brauchen dafür das 296- bzw. 328-Fache an Rechenzeit.

3. Und: Die Verfahrenswahl ist gar nicht der entscheidende Hebel. Zwischen den Verfahren liegen wenige RMSE-Punkte, zwischen den möglichen Ansatzformen liegen Tausende. Die Arbeit zieht daraus eine übertrag-bare Regel für ähnliche Aufgaben: Dass ein linearer Ansatz den Daten nachweislich nicht ganz gerecht wird, be-gründet für sich genommen noch kein aufwendigeres Verfahren — solange die Prüfung Tausende voneinander abhängiger Zeilen behandelt, als wären sie unabhängig. Entschieden wird die Frage über wenige Dutzend wirk-lich unabhängige Einheiten, und dort gewinnt hier das billigste Modell im Feld.

Was diese Zusammenfassung nicht behauptet

Die folgenden Punkte werden hier ausdrücklich als offen gekennzeichnet, weil die Arbeit sie selbst nicht abschließend ent-scheidet. **Welche der beiden Auswertungen die „richtige“ ist** — die Kreuzvalidierung ist die belastbarere, aber die Arbeit erklärt keine der beiden Rangfolgen für ungültig. **Warum genau sich die Rangfolgen umkehren** — die Arbeit nennt für die Einsatzart zwei mögliche Erklärungen und lässt beide nebeneinander stehen. **Ob die Ergebnisse auf andere Städte über-tragbar sind** — die Arbeit nennt dafür zwei Voraussetzungen (ein monatlich fortgeschriebenes Merkmal und eine vergleich-bare polizeiliche Meldepraxis) und prüft sie nicht. Die **Aufmerksamkeitsanteile** in der letzten Tabelle stammen aus dem Poisson-Modell des Mengenstrangs; für die Einsatzart gelten andere Werte, und die Arbeit weist darauf hin, dass sich die bei-den Baumverfahren darin nicht direkt vergleichen lassen.

Grundlage dieser Zusammenfassung: Bachelorarbeit „Vorhersage von Feuerwehreinsätzen auf Basis struktureller und so-zioökonomischer Merkmale“ (Stand der vorgelegten Fassung), insbesondere Kapitel 1 bis 7, Tabellen 3, 5, 6, 10 bis 15 sowie Abbildungen 1, 5, 6, 8 und 10; ergänzend die Ergebnisdateien im Ordner *results* des Projektverzeichnis. Alle Zahlenwerte

wurden gegen beide Quellen abgeglichen. Die Abbildungen dieser Zusammenfassung wurden eigens dafür gezeichnet und sind keine Reproduktionen der Originalabbildungen; wo sie Beispielwerte zeigen, ist das in der Bildunterschrift vermerkt.