

vorprüfung/ — die Messlatte und ihre Berechtigung

Bevor ein Vergleichsverfahren antritt, muss feststehen, was es schlagen soll und warum es überhaupt antreten darf. Sechs Dateien beantworten das.

BACHELORARBEIT

SFFD-Einsatzprognose

PHASE

CRISP-DM 4 — Vorstufe

ERGEBNIS

Baselines · Eignungsprüfung · Obergrenzen

Was dieser Ordner leistet

Er beantwortet drei Fragen, die vor jedem Verfahrensvergleich geklärt sein müssen.

1 · WORAN WIRD GEMESSEN?

Ein Ergebnis ohne Bezugspunkt ist keines. `v1_baselines.py` baut zwei Messlatten und lässt sie unter demselben Protokoll mitlaufen wie die Modelle.

- Stufe 1 — trivial, ohne jedes Merkmal
- Stufe 2 — die einfachste zur Datenform passende Form

2 · DÜRFEN DIE VERFAHREN ANTRETEN?

`v2_eignung.py` prüft, ob die Datenform die gewählten Verfahren überhaupt rechtfertigt — mit formalen Tests statt Augenmaß.

- sechs Belege, davon einer als Auflage Schröter
- Anforderungen je Verfahren mit p-Wert

3 · WAS IST ÜBERHAUPT ERREICHBAR?

`v3` und `v4` stecken die Grenzen ab: Wie viel Struktur überträgt sich, und wo liegt die Obergrenze der Klassifikation?

- `v3` — hält die Nichtlinearität out-of-sample?
- `v4` — zwei Decken über dem Strukturstrang

WARUM DAS EINE EIGENE STUFE IST

Ohne diesen Ordner wäre jeder Vergleich eine Rangliste ohne Maßstab. Erst die Messlatte macht aus „Random Forest erreicht RMSE 36,4“ eine Aussage — nämlich, ob sich der Mehraufwand gegenüber einem GLM gelohnt hat.

Die sechs Dateien

DATEI	BEANTWORTET	ERZEUGT	LÄUFT ÜBER
run.py	Startet die zwei Pflichtschritte	nichts eigenes	run.py
v0_aufteilung.py	Wie entstehen die 10 Wiederholungen?	keine Datei — liefert Datenrahmen	einzeln
v1_baselines.py	Was müssen die Verfahren schlagen?	baselines_*.csv	run.py
v2_eignung.py	Passen die Verfahren zur Datenform?	eignungspruefung.md, annahmen.csv	run.py
v3_spezifikation.py	Überträgt sich die Nichtlinearität?	spezifikation_*.csv	einzeln
v4_decke.py	Wie gut kann die Klassifikation werden?	decke*.csv, decke.md	einzeln

REIHENFOLGE

python vorpruefung/run.py fährt v1 und dann v2 — zwingend in dieser Reihenfolge, weil die Eignungsprüfung die Baseline - Werte **liest** statt sie neu zu rechnen. v0 ist ein Selbsttest, v3 und v4 sind eigenständige Zusatzbelege.

Das Stufenmodell der Baselines

Die zentrale Begriffsordnung des gesamten Projekts.

STUFE 1

Triviale Referenz

Benutzt KEIN Merkmal. Gesamtmittelwert bzw. häufigste Klasse. Frage: steckt in den Merkmalen überhaupt Information?



STUFE 2

Einfachste passende Form

Benutzt alle Merkmale, aber in der simpelsten Form. Poisson-GLM bzw. multinomiales Logit. Kein freier Hyperparameter.



STUFE 3

Vergleichsverfahren

Ridge, Random Forest, XGBoost in modelle/. Sie müssen STUFE 2 schlagen, nicht Stufe 1.

DIE REGEL, DIE DARAUS FOLGT

Wer einen freien Parameter hat, wird mit demselben Budget getunt. Wer keinen hat, wird angepasst. **Kein Modell läuft mit einer unbegründeten Voreinstellung.**

DER HÄUFIGSTE LESEFEHLER

Stufe 2 ist im Mengenstrang ein **Poisson-GLM**, im Strukturstrang ein **multinomiales Logit**. Das sind zwei verschiedene Modelle. „Die Baseline gewinnt“ gilt immer nur für einen der beiden Stränge.

DATEI

v0_aufteilung.py

Die eine Stelle, an der die Fold-Zuteilung je Wiederholung entsteht. Ohne sie wären die zehn Wiederholungen wertlos.

201

Zeilen

4

Funktionen

10

Wiederholungen

Warum diese Datei existiert

Die Grundaufteilung steht bereits als Spalte in der Parquet-Datei — sie reicht für die Wiederholungen trotzdem nicht.

DER NAHELIEGENDE WEG — UND WARUM ER SCHEITERT

- Ein **Versatz** würde die Stadtteile reihum um n Plätze verschieben.
- Zwei Stadtteile landen aber genau dann in derselben Gruppe, wenn ihre Plätze modulo 6 übereinstimmen — **unabhängig vom Versatz**.
- Der Versatz rotiert also nur die *Beschriftung* der Gruppen, nicht ihre Zusammensetzung.

DER ZWEITE, SCHLIMMERE FEHLER

- Rotiert die Beschriftung, rotiert auch Gruppe 0 — und **Gruppe 0 ist das Hold-out**.
- Gemessen: bei Versatz 1 liegt kein einziger der sechs ursprünglichen Hold-out-Stadtteile mehr im Hold-out.
- Die Wiederholungen 1 bis 9 hätten auf genau den Stadtteilen trainiert, die unberührt bleiben müssen.

DIE LÖSUNG

Gemischt wird **innerhalb der Rangblöcke**: Block 0 sind die Plätze 0–4, Block 1 die Plätze 5–9 und so fort. Jeder Fold bekommt weiterhin genau einen Stadtteil aus jedem Block — die doppelte Stratifizierung überlebt, die Foldgrößen bleiben 6/6/6/6/5, aber die **Zusammensetzung** ändert sich wirklich.

Die vier Funktionen

SELTEN_JE_STADTTEIL(KLASSIFIKATION)

EIN klassifikation.parquet

AUS Reihe Stadtteil → Zahl brand-dominierter Monate

- Das Stratifizierungsmaß. Steht in keiner Datei, deshalb muss auch der Regressionsstrang die Klassifikationsdatei mitlesen.
- **Kein Leakage:** geht in kein Modell ein, bestimmt nur die Testgruppen.

WIEDERHOLTE_AUFTEILUNG(DATEN, WIEDERHOLUNG, SELTEN)

EIN Datenrahmen, Wiederholung 0–9, das Stratifizierungsmaß

AUS Kopie mit neu belegter fold-Spalte

- Wiederholung 0 reproduziert die Datei **bitgenau** — geprüft per `assert`, nicht behauptet.
- Hold-out-Zeilen behalten `fold = 0` und bleiben in jeder Wiederholung ausgeschlossen.

ENTWICKLUNG_UND_HOLDOUT(DATEN)

- Liefert zwei Masken: 29 Entwicklungs- gegen 6 Hold-out-Stadtteile.
- Die **einzige** Stelle im Repository, die `ist_holdout = 1` auswertet.

_SELBSTTEST()

- Prüft Foldgrößen, mindestens einen Brand-Testfall je Fold, unverändertes Hold-out, zehn verschiedene Partitionen ohne Dubletten.
- Und: kein Stadtteil je zugleich Trainings- und Testfall.

KOLLOQUIUMSFRAGE

„**Warum brauchen Sie zehn Wiederholungen?**“ — Bei 29 Entwicklungsstadtteilen schwankt ein einzelner Fold stark. Die Wiederholungen dienen der **Streuungsschätzung**, nicht der Modellwahl. Alle drei Aufrufer müssen dieselbe Zuteilung sehen, sonst testet der gepaarte Wilcoxon still auf verschiedenen Zeilen.

DATEI

v1_baselines.py

Die Messlatte. Zwei Stufen, beide Stränge, unter demselben Protokoll wie die Vergleichsverfahren.

330

Zeilen

8

Funktionen

250

Läufe

Warum die Baseline mitläuft statt nur zu existieren

Eine Ergänzung, die den Charakter der Datei geändert hat.

VORHER

- Es lief nur die Aufteilung, die als `fold` -Spalte in der Datei steht — also **fünf** Läufe.
- Die Vergleichsverfahren erzeugen **fünfzig**.
- Für 45 der 50 Läufe gab es keinen Gegenwert.

NACHHER

- Die Baseline läuft über alle 10 Wiederholungen × 5 Folds.
- Die Primäraussage ist ein **gepaarter** Test „Verfahren gegen Stufe 2“ — der braucht je Lauf einen Gegenwert auf **denselben** Testzeilen.
- Damit ist die Baseline ein **Mitbewerber unter identischem Protokoll**, kein Referenzwert.

250

Baseline-Läufe

200

Zeilen Regression

wenige s

Rechenzeit

Auflage C

Schröter: gleiche Merkmale und Splits

poisson_glm(train, test, merkmale)

Stufe 2 des Mengenstrangs — das Modell, das am Ende kein Vergleichsverfahren schlägt.

EIN Trainings- und Testrahmen, optional ein reduzierter Merkmalssatz

AUS Vorhersagen auf der Originalskala, eine Zahl je Stadtteil-Monat

DIE SPEZIFIKATION

- Poisson-GLM mit kanonischem $\log$ -Link, unpenalisierte Maximum-Likelihood.
- $\log(\text{Bevölkerung})$ geht als **Offset** ein — Koeffizient fest auf 1.
- Das Modell schätzt Einsätze **je Einwohner** und rechnet am Ende hoch.
- Ohne den Offset sagt es vor allem die Stadtteilgröße vorher.

WARUM POISSON UND NICHT NEGATIVE BINOMIAL

- Die Daten sind überdispers (Index 62,8), die Annahme $\text{Var} = \mu$ also verletzt.
- Beschädigt werden dadurch die **Standardfehler**, nicht die Konsistenz des bedingten Mittelwerts (Gourieroux, Monfort & Trognon 1984).
- Diese Baseline liefert **nur Punktvorhersagen** — keine Koeffiziententests, keine Konfidenzintervalle. Sie ist davon nicht betroffen.

KOLLOQUIUMSFRAGE

„**Wo kommt die zweite Zielgröße her?**“ — Aus derselben Anpassung, geteilt durch die Bevölkerung. Ein eigenes Ratenmodell wäre eine *zweite Spezifikation* und damit unfair gegenüber den Vergleichsverfahren.

logit_glm(train, merkmale)

Stufe 2 des Strukturstrangs — und ein behobener Konstruktionsfehler.

EIN Trainingsrahmen, optional ein reduzierter Merkmalssatz

AUS das angepasste MODELL, nicht die Vorhersage

DIE SPEZIFIKATION

- Multinomiales Logit, linear in den Log-Odds, unpenalisiert ($C = \infty$).
- Kein freier Hyperparameter, also kein Tuning.
- `class_weight="balanced"` statt Resampling — **kein SMOTE**, keine duplizierte oder gelöschte Zeile.

WARUM DAS MODELL ZURÜCKKOMMT

- Beide Aufrufer brauchen aus **derselben** Anpassung drei Dinge: Klassenvorhersage, Wahrscheinlichkeiten und die Klassenreihenfolge.
- Ein zweites Fitten dafür wäre Verschwendung.
- Konvergenzwarnungen werden **nicht** abgefangen — der Aufrufer zählt und berichtet sie.

DER BEHOBENE FEHLER — EINE ASYMMETRIE

Bis zum 10.08.2026 baute `m03_struktur.hold_out()` dieses Modell ein **zweites Mal** nach: dieselben vier Argumente, an zwei Orten aufgeschrieben. Ändert jemand eines davon, misst die Kreuzvalidierung still gegen ein anderes Modell als die Schlussbewertung — und keine Prüfung schlägt an. Der Mengenstrang war immer richtig gebaut; der Fehler war die Asymmetrie zwischen beiden.

Die Auswertungsfunktionen

Wie aus 250 Läufen berichtbare Zahlen werden.

REGRESSION(PANEL, SELTEN) · KLASSIFIKATION(KL, SELTEN)

EIN das jeweilige Panel und das Stratifizierungsmaß

AUS Datenrahmen der Einzelläufe

- Regression: 200 Zeilen — 50 Läufe × 2 Zielgrößen × 2 Modelle.
- Klassifikation: Stufe 1 sagt immer die häufigste Klasse. **Accuracy hoch, Macro-F1 niedrig** — genau deshalb ist Macro-F1 maßgeblich.

BEWERTE_REGRESSION(Y_TRUE, Y_PRED)

- RMSE, MAE und R^2 — immer auf der **Originalskala** der Zielgröße.

_ZWEISTUFIG(DF, SCHLUESSEL, MASSE)

EIN Datenrahmen der Einzelläufe

AUS je Modell eine Zeile mit beiden Streuungen

- **Stufe 1:** je Wiederholung über die 5 Folds mitteln.
- **Stufe 2:** die Streuung *dieser zehn* Werte berichten.
- `std_folds` über alle 50 Läufe ist zu optimistisch — es sind dieselben 29 Stadtteile in zehn Gruppierungen.

_MACRO_AUROC(...)

- Liefert `NaN`, wenn im Testfold eine Klasse fehlt — **nicht 0,5 und nicht 0**.
- Ein erfundener Wert zöge den Mittelwert nach unten und sähe wie ein Messergebnis aus.

DATEI

v2_eignung.py

Sechs Belege, dass die gewählten Verfahren zur Datenform passen. Abschnitt 6 ist eine ausdrückliche Auflage des Betreuers.

667

Zeilen

12

Funktionen

6

Belege

Die sechs Belege im Überblick

#	FUNKTION	BEFUND	KONSEQUENZ
1	dispersion()	Zählraten sind überdispers (Index 62,8)	zählratengerechte Verlustfunktionen
2	linearitaet()	Pearson und Spearman klaffen auseinander	Ridge auf $\log(1+y)$, nicht roh
3	spezifikation()	RESET verwirft die lineare Form	Random Forest und XGBoost
4	extrapolation()	Teststadtteile liegen oft außerhalb	Limitation, keine Verfahrensfrage
5	klassifikation()	Merkmale trennen auch die Einsatzart	zweiter Strang gerechtfertigt
6	annahmen()	Anforderungen je Verfahren, mit p-Wert	Auflage Schröter vom 10.08.2026

WO GERECHNET WIRD

Ausschließlich auf den **Trainingsstadtteilen von Fold 1** — die Teststadtteile dürfen keine Modellentscheidung beeinflussen. Ausgenommen sind Abschnitt 4 und die aus v1 gelesenen Referenzwerte.

WAS DIE PRÜFUNG NICHT LEISTET

Sie unterscheidet **nicht** zwischen Random Forest und XGBoost. Welche der beiden Strategien gewinnt, ist die empirische Forschungsfrage der Arbeit — vorab nötig ist nur, dass beide plausibel sind.

dispersion(train)

Beleg 1 — und ein Beispiel dafür, wie Dokumentation von der Umsetzung wegdriften kann.

EIN Trainingszeilen von Fold 1

AUS Textabschnitt im Bericht, Dispersionsindex je Zielgröße

DIE MESSUNG

Der Index `Varianz / Mittelwert` misst, wie weit die Zählraten die Poisson-Annahme `Var =  $\mu$` verletzen. Gemessen: **62,8**.

FOLGE 1 — VERLUSTFUNKTION

Ein quadratischer Fehler auf rohen Zählraten ist bei diesem Index unangemessen. Daraus folgen `reg:tweedie` für XGBoost und `criterion="poisson"` für den Random Forest.

FOLGE 2 — BASELINE

Beschädigt sind die **Standardfehler**, nicht die Konsistenz des bedingten Mittelwerts. Eine Baseline mit reinen Punktvorhersagen ist nicht betroffen — das Poisson-GLM bleibt Stufe 2.

WAS HIER GELERNT WURDE

Bis zum 10.08.2026 schloss dieser Abschnitt aus der Überdispersion, Poisson scheide aus. Die Entscheidung dagegen fiel am 06.08. — der Abschnitt argumentierte danach **gegen die eigene Umsetzung**, und der erzeugte Bericht trug den Widerspruch weiter. Kein Rechenfehler, sondern Drift. Der gemessene Index ist unverändert; er trägt nur eine andere Schlussfolgerung.

Belege 2 bis 5

LINEARITAET(TRAIN)

EIN Trainingszeilen von Fold 1

AUS Textabschnitt und zwei Abbildungen

- Pearson misst den **linearen**, Spearman den **monotonen** Zusammenhang — klaffen sie auseinander, ist der Zusammenhang gekrümmt.
- Bewertet wird nur, wo die Korrelation substanziell ist; nahe null ist der Abstand Rauschen.
- Auflage R7: erst plotten, dann über lineare Modelle reden.

SPEZIFIKATION(TRAIN)

EIN Trainingszeilen von Fold 1

AUS F-Wert, p-Wert, adjustiertes R^2

- Der RESET-Test prüft, ob Potenzen der Vorhersage noch etwas erklären. **F = 215,2**.
- 45 Interaktionsterme heben das adjustierte R^2 von 0,805 auf 0,919.
- Beides sind **In-Sample**-Größen — die Übertragung prüft v3.

EXTRAPOLATION(PANEL)

- Anteil der Testzeilen außerhalb der Trainingsspanne.
- Ein hoher Anteil ist eine **Limitation der Datenlage**, keine Verfahrensfrage: Baumverfahren extrapolieren grundsätzlich nicht.

KLASSIFIKATION(KL)

- Kruskal-Wallis je Merkmal über die vier Klassen — nichtparametrisch, verträgt ungleich große Gruppen.
- Trennt kein Merkmal, ist die Zielgröße für **jedes** Verfahren nicht vorhersagbar.
- Eigene Frage: Krümmung bei der *Anzahl* sagt nichts über die *Art*.

annahmen(train, befunde)

Beleg 6 — die Auflage. Und die Zeilensorte, auf die es ankommt.

EIN Trainingszeilen von Fold 1, Klassifikationspanel

AUS Textabschnitt, annahmen.csv, qq_residuen.csv

DREI SORTEN VON ZEILEN

- **erfüllt** — die Anforderung besteht und ist eingehalten
- **verletzt** — sie besteht und ist verletzt; dann steht in der Spalte „Konsequenz“, was daraus folgt
- **nicht erforderlich** — das Verfahren stellt diese Anforderung gar nicht

DREI NEUE TESTS

- **Cameron & Trivedi (1990)** — Hilfsregression auf Überdispersion. Der Index aus Abschnitt 1 ist eine Kennzahl, *kein* Test.
- **Breusch-Pagan** — Varianzgleichheit, wörtlich in der Auflage genannt.
- **Jarque-Bera** — Normalität der Residuen samt Schiefe und Wölbung.

WARUM DIE DRITTE SORTE DIE WICHTIGSTE IST

Dass Random Forest keine Verteilungsannahme hat, ist eine **Aussage über das Verfahren** — und der halbe Grund, warum es im Vergleich steht. Eine Tabelle, die nur verletzte Annahmen zeigt, lässt Baumverfahren voraussetzungslos aussehen; eine, die sie ganz weglässt, beantwortet die Auflage nicht.

WAS HIER BEWUSST NICHT STEHT

- Die **Multikollinearität**. Der VIF wird in `m04_shap._vif()` gerechnet, weil seine einzige echte Konsequenz die Interpretation der Beiträge betrifft.
- Ihn hier zu wiederholen hieße, dieselbe Zahl an zwei Orten zu führen — genau die Fehlerquelle, die `tools/pruefe_zahlen.py` bewacht.

Die Hilfsfunktionen

Formatierung ist hier kein Beiwerk — sie entscheidet über Maschinenlesbarkeit.

LOG(TXT) · SPEICHERE(FIG, NAME)

- `log()` gibt eine Zeile aus **und** hängt sie an den Berichtstext an — der Bericht entsteht nebenbei.
- `speichere()` legt eine Abbildung ab und vermerkt sie im Bericht.

_Z(WERT, STELLEN) · _P(WERT)

- Deutsches Dezimalkomma auf Teststatistik und p-Wert.
- Unter 0,001 wird **begrenzt statt beziffert**: `4.0e-47` ist keine lesbare Information, die Aussage lautet „praktisch null“.
- Bei $n = 3\,036$ findet ein Test fast jede Abweichung — die Effektgröße trägt, nicht die Nachkommastelle.

Z(...) — EINE ZEILE DER ANFORDERUNGSTABELLE

- `statistik` ist die **lesbare** Fassung mit Dezimalkomma, `wert` dieselbe Zahl **maschinenlesbar**.
- Beides, weil `tools/pruefe_zahlen.py` den Sollwert aus dieser Datei zieht. Eine Zeichenkette, die man parst, ist eine Zeichenkette, die sich beim nächsten Formatwechsel anders parst.

MAIN()

- Rechnet die sechs Belege und schreibt Bericht, Tabellen und Abbildungen.
- Abschnitt 6 **übernimmt** die Kennzahlen aus 1, 3 und 4, statt sie neu zu rechnen — zweimal gerechnet hieße zwei Zahlen, die auseinanderlaufen können.

DATEI

v3_spezifikation.py

Hält die diagnostizierte Nichtlinearität auch out-of-sample? Die Antwort trägt den stärksten Befund der Arbeit.

242

Zeilen

6

Funktionen

200

Anpassungen

Die Frage hinter der Datei

v2 stellt eine Diagnose. Diese Datei prüft, ob sie sich überträgt.

WAS V2 ZEIGT — IN-SAMPLE

- RESET verwirft die lineare Spezifikation deutlich (**F = 215,2**).
- 45 Interaktionsterme heben das adjustierte R^2 von 0,805 auf 0,919.
- Beide Kennzahlen behandeln 3 828 Zeilen als **unabhängig**.

WARUM DAS NICHT REICHT

- Tatsächlich liegen **29 unabhängige Stadtteile** mit je 132 Monaten vor.
- Ein F-Test mit $n = 3\,828$ findet praktisch jede Abweichung signifikant.
- Adjustiertes R^2 korrigiert für die Zahl der Parameter — nicht für die geklumpnte Struktur.

DIE ZWEI FRAGEN, SAUBER GETRENNT

Diagnose (v2): *Steckt* in diesen Daten Struktur jenseits der Geraden?

Übertragung (v3): *Überträgt* sich diese Struktur auf unbekannte Stadtteile?

KEIN MODELLVORSCHLAG

Keine der drei Erweiterungen tritt im Verfahrensvergleich an. Sie dienen ausschließlich der Interpretation des Hauptbefundes.

Die vier Spezifikationen

Grundlage ist immer das Stufe-2-Poisson-GLM — nur die Merkmalsmatrix wächst.

SPEZIFIKATION	TERME	ZUSÄTZLICH ENTHALTEN
linear		12 die 10 Prädiktoren + monat_sin + monat_cos
quadratic		22 die Quadrate der 10 Prädiktoren
interaktionen		57 alle 45 Paarprodukte der Prädiktoren
beides		67 Quadrate und Paarprodukte

WARUM DIE SAISONTERME AUSSEN VOR BLEIBEN

$\text{monat_sin}^2 + \text{monat_cos}^2 = 1$ ist exakt kollinear mit der Konstanten — das Modell wäre nicht identifiziert. Sie werden weder quadriert noch gekreuzt.

WARUM STANDARDISIERT WIRD

Das Quadrat des Medianeinkommens liegt bei $1e10$, das Produkt zweier Prädiktoren bei $1e9$ — die IRLS-Iteration bricht auf dieser Konditionierung zusammen. **Mathematisch ist die Standardisierung folgenlos:** der aufgespannte Raum ist derselbe.

DIE SELBSTPRÜFUNG, DIE DARAUS FOLGT

Weil die Standardisierung folgenlos ist, **muss** die Spalte `linear` die Stufe-2-Baseline aus v1 exakt reproduzieren. `_selbsttest()` prüft das auf drei Nachkommastellen und bricht sonst ab — weicht sie ab, sieht dieses Skript andere Merkmale oder andere Folds, und jeder Vergleich darin ist wertlos.

Die sechs Funktionen

ENTWERFE(TRAIN, TEST, SPEZIFIKATION)

- Baut die Merkmalsmatrizen, jeweils mit Konstante an Position 0.
- Mittelwert und Streuung stammen **nur aus dem Training** — der Teststadtteil darf die Transformation nicht mitbestimmen.
- Quadrate und Paarprodukte entstehen erst **nach** der Standardisierung.

EIN_LAUF() · ALLE_LAEUFE() · ZWEISTUFIG()

- ein_lauf : eine Poisson-Anpassung, eine Bewertung auf der Originalskala.
- alle_laeufe : 10 Wiederholungen × 5 Folds × 4 Spezifikationen = **200 Anpassungen**.
- zweistufig : dieselbe Mittelungsregel wie überall — maßgeblich ist die Streuung der zehn Wiederholungsmittel.

KONVERGENZ — EIN BEFUND, KEIN ÄRGERNIS

Mit 67 Termen auf 3 036 Trainingszeilen konvergiert die IRLS-Iteration nicht in jedem Fold. Nicht konvergierte Anpassungen werden **gezählt und mitberichtet**, nicht stillschweigend übergangen und nicht entfernt — sie sind Teil des Befundes, dass diese Spezifikation zu den Daten nicht passt.

DER PRÜFAUFTRAG, AUF DEN ES ANKOMMT

Ist der Abstand `linear ↔ interaktionen` größer als der Abstand `linear ↔ Random Forest`? **Nur dann** trägt die Aussage: die Spezifikation bewegt mehr als die Verfahrenswahl.

DATEI

v4_decke.py

Zwei Obergrenzen über dem Strukturstrang. Sie verwandeln ein schwaches Ergebnis in einen methodischen Befund.

307

Zeilen

7

Funktionen

200

Bootstrap-Ziehungen

Warum es diese Datei gibt

Der Strukturstrang erreicht Macro-F1 um 0,33. Gegen 1,0 gehalten sieht das misslungen aus — und diese Lesart ist falsch.

DER DENKFEHLER

Ein Macro-F1 von 0,33 gegen die **1,0** einer fehlerfreien Vorhersage zu halten unterstellt, dass 1,0 bei dieser Zielgröße und diesem Merkmalssatz überhaupt erreichbar wäre. Das ist sie nicht.

DIE ANTWORT

- Zwei Obergrenzen begrenzen den Strukturstrang.
- Beide entstehen **vor jeder Modellwahl** — die eine in der Konstruktion der Zielgröße, die andere in der Struktur der Merkmale.
- Sie zu beziffern ist keine nachträgliche Entlastung, sondern die Voraussetzung dafür, 0,33 überhaupt einordnen zu können.

0,6404

Decke A — Label-Rauschen

0,4572

Decke B — Stadtteilwissen

0,22

Mehrheitsklasse

~0,33

erreicht

DIE RICHTIGE FRAGE

Nicht „warum nur 0,33?“, sondern: **Wie viel des überhaupt Erreichbaren wird ausgeschöpft?**

decke_a(panel) — das Label-Rauschen

Die Obergrenze, die schon in der Konstruktion der Zielgröße steckt.

EIN Panel mit den vier Anteilsspalten und der Einsatzzahl N

AUS mittlerer Macro-F1, Streuung über die Ziehungen, Kippanteil

DAS PROBLEM

- `dominante_einsatzart` ist **kein beobachtetes Merkmal**, sondern der `argmax` über vier Anteilsspalten desselben Stadtteil-Monats.
- Wo zwei Anteile dicht beieinander liegen, entscheidet der **Zufall der Monatsziehung**, welche Klasse gewinnt — nicht die Struktur des Stadtteils.

DIE MESSUNG

- Parametrischer Bootstrap: jeder Stadtteil-Monat wird aus `Multinomial(N, p_beobachtet)` neu gezogen.
- Der Macro-F1 zwischen beobachtetem und neu gezogenem Label ist die Güte eines Modells, das die wahren Klassenwahrscheinlichkeiten **exakt kennt**.
- **Kein Verfahren kann darüber hinaus.**

FALLSTRICKE

Zeilen mit `N = 0` werden **ausgeschlossen**, nicht auf eine Klasse gesetzt — `rng.multinomial` lieferte sonst stumm einen Nullvektor, dessen `argmax` immer auf die erste Klasse zeigt. Und der Bootstrap braucht einen festen `RANDOM_STATE`, sonst schwankt Decke A zwischen zwei Läufen und die Zahl in der Arbeit passt nicht mehr zur Zahl in der CSV.

decke_b(panel) — die Grenze des Stadtteilwissens

Die bindende Obergrenze. Sie folgt direkt aus der Merkmalsstruktur.

EIN Panel mit Stadtteil- und Klassenspalte

AUS Macro-F1 der Zuweisung, Trefferanteil, Verteilung der Modalklassen

DIE HERLEITUNG

- Alle Prädiktoren sind **stadtteilgebunden**: die baulichen konstant über den gesamten Zeitraum, die sozialen konstant je Stadtteil-Jahr, der Kriminalitätsindex zu 90 % zwischen den Stadtteilen.
- Ein Modell kann daraus nur **Stadtteilwissen** ziehen.
- Die Obergrenze ist damit die Güte einer Vorhersage, die jedem Stadtteil-Monat die **Modalklasse seines Stadtteils** zuweist.

WARUM SIE SO TIEF LIEGT

Decke B liegt **deutlich unter** Decke A. Der Grund steht in der Ergebnistabelle: Die Modalklassen der Stadtteile sind fast alle dieselbe. Stadtteilwissen unterscheidet die Stadtteile also kaum.

KOLLOQUIUMSFRAGE

„**Woher wissen Sie, dass Decke B die bindende ist?**“ — Weil sie unter Decke A liegt. Ein Prüfauftrag der Datei lautet genau so: Liegt Decke B *unter* Decke A? Wenn nicht, ist etwas falsch — Stadtteilwissen kann das Label-Rauschen nicht unterbieten.

Die übrigen Funktionen

MARGE(PANEL)

EIN Panel mit den vier Anteilsspalten

AUS Verteilung des Abstands top1 – top2

- Ein kleiner Abstand heißt: das Label hätte bei einer anderen Monatsziehung anders gelautet.
- Macht sichtbar, wie groß der Anteil solcher Zeilen ist.

AUSSCHOEPFUNG(MODELLE, BASIS, A, B)

EIN Modellwerte, Mehrheitsklassen-Basis, Decke A und B

AUS eine Quote je Verfahren und Decke

- $(\text{Modell} - \text{Mehrheitsklasse}) / (\text{Decke} - \text{Mehrheitsklasse})$
- Der Rohquotient $\text{Modell}/\text{Decke}$ wäre **geschönt**: Der Sockel von Macro-F1 0,22 ist keine Leistung des Modells.

BERICHT(...) · MAIN(ARGV) · _MACRO_F1(A, B)

- `bericht` ist reine Formatierung — hier wird nichts gerechnet. Ziehungszahl und Startwert stehen im Kopf, damit die Datei ohne den Code lesbar bleibt.
- `main` filtert ohne das Argument `holdout` auf `ist_holdout = 0`. Die Decke ist zwar eine Eigenschaft der *Zielgröße* und berührt keinen Prädiktor — die Sperre gilt trotzdem konstruktiv, nicht nach Ermessen.

WIE DIE ZAHLEN ZU LESEN SIND

- **Decke A ist eine Obergrenze, kein Zielwert.** Dass ein Modell sie nicht erreicht, ist kein Mangel.
- Bindend ist Decke B.

Was man über diesen Ordner wissen muss

1 · DIE BASELINE IST EIN MITBEWERBER

Sie läuft über dieselben 50 Läufe, dieselben Folds und dieselben Merkmale wie die Vergleichsverfahren. Nur so lässt sich **gepaart** testen — und nur so erfüllt der Vergleich Auflage C.

2 · DIE VERFAHRENSWAHL IST BELEGT

Sechs Belege, davon einer als ausdrückliche Auflage. Die Prüfung entscheidet **nicht** zwischen Random Forest und XGBoost — das ist die empirische Forschungsfrage.

3 · DIE GRENZEN SIND BEZIFFERT

v3 zeigt, dass die Spezifikation mehr bewegt als die Verfahrenswahl. v4 zeigt, dass über dem Strukturstrang eine Decke bei 0,4572 liegt. Beides sind **Befunde**, keine Entschuldigungen.

DER SATZ, MIT DEM MAN DEN ORDNER VERTEIDIGT

„Die Vorprüfung sagt, woran gemessen wird und was überhaupt messbar ist — bevor das erste Vergleichsverfahren startet.“ Ohne sie wäre jedes Ergebnis eine Rangliste ohne Maßstab.