

Risiken für die Modellierung

Data Preparation abgeschlossen · Datensatz final · alle Zahlen aus den fertigen Dateien nachgerechnet, Stand 28.07.2026

Ausgangslage

Die Data Preparation ist abgeschlossen. Ein Befehl, zwei modellfertige Datensätze auf derselben Analyseeinheit, Baselines für beide Stränge, 18 von 18 Prüfungen bestanden. Der Datensatz gilt ab jetzt als fest.

Die hier gelisteten Risiken betreffen deshalb ausschliesslich die **kommende Modellierung**. Es sind keine Fehler in den Daten, sondern Eigenschaften der Fragestellung, die die Aussagekraft der Ergebnisse begrenzen. Zwei davon betreffen das zentrale Versprechen der Arbeit – den Vergleich der drei Verfahren.

1. Risikoregister

Sortiert nach Dringlichkeit. Alle Belege sind auf dem finalen Datensatz gerechnet.

	Risiko und Wirkung	Beleg	Stufe
R-1	Die drei Verfahren sind möglicherweise nicht unterscheidbar Das ist die zentrale Forschungsfrage. Selbst im gepaarten Vergleich über 20 Fold-Ergebnisse liegt der Unterschied zwischen Ridge und Random Forest bei $+0,042 \pm 0,609$ – Ridge gewinnt in 12 von 20 Fällen, also praktisch Münzwurf.	Ridge $+0,078 \pm 0,63$ RF $+0,036 \pm 0,44$ Differenz $\pm 0,61$	hoch
R-2	31 % der Testzeilen liegen ausserhalb des Trainingsbereichs Unvermeidliche Folge des Stadtteil-Splits: Ein zurückgehaltener Stadtteil ist fast immer in irgendeinem Merkmal extrem. Baumverfahren können dort nicht extrapolieren, Ridge rechnet linear weiter – die Verfahren werden ungleich getroffen.	Fold 3: 50 % Fold 5: 49 % Mittel: 31,3 %	hoch
R-3	Brand ist in einzelnen Folds mit 1–2 Fällen besetzt Macro-F1 über vier Klassen, von denen eine mit einem einzigen Testfall vertreten ist, schwankt allein durch diesen einen Fall.	Fold 2: 1 Brand-Zeile Fold 3: 2 · Fold 5: 5	hoch
R-4	Zwei Anteile sind nicht vorhersagbar <i>anteil_brand</i> und <i>anteil_rettung_ems</i> liegen im Vortest unter ihrer eigenen Baseline. Ein ehrliches Ergebnis – aber der Strukturteil trägt damit weniger, als die Forschungsfrage verspricht.	Brand $-0,109$ Rettung/EMS $-0,309$	mittel
R-5	Abweichungen vom Exposé sind unbesprochen Zeitreihen-Kreuzvalidierung entfällt als Hauptvergleich; in der Klassifikation rechnet logistische Regression statt Ridge; die Einsatzart wird auf Stadtteilebene bestimmt. Alle drei sind begründet, keine ist abgestimmt.	Decision Log #29	mittel
R-6	Das Hold-out umfasst nur 6 Stadtteile Die abschliessende, einmalige Bewertung beruht auf sechs Einheiten. Ihre Unsicherheit muss mitberichtet werden.	6 von 35 792 Zeilen (17 %)	mittel
R-7	Effektive Stichprobe: 35 Einheiten 4.620 Zeilen klingen komfortabel, es sind 35 Querschnitteinheiten $\times$ 132 Monate. Das ist die gemeinsame Ursache von R-1, R-2, R-3 und R-6.	35 Stadtteile	mittel

	Risiko und Wirkung	Beleg	Stufe
R-8	Merkmale sind innerhalb eines Jahres konstant ACS erscheint jährlich, Land Use ist ein Snapshot von 2020. Das Modell sagt für alle zwölf Monate fast denselben Wert vorher; die Monatsschwankung geht ins Residuum.	5 Jahrgänge auf 132 Monate	gering
R-9	ACS-Trefferquote 2009 nur 63,1 % Für die Hauptanalyse ab 2015 folgenlos, gehört aber in die Limitationen.	2021/23: 99,2 %	gering

2. R-2: Was „ausserhalb des Trainingsbereichs“ bedeutet

Es ist **kein** Hinweis auf einen Fehler im Test – im Gegenteil, es ist die Folge davon, dass korrekt out-of-sample getestet wird. Gemeint ist der Wertebereich der Merkmale: Liegt der höchste Altbauanteil im Training bei 65 % und hat der zurückgehaltene Stadtteil 78 %, hat das Modell so einen Stadtteil nie gesehen. Sobald man ganze Stadtteile zurückhält, ist das unvermeidlich.

Warum das den Vergleich verzerrt

Die Folge trifft die Verfahren **ungleich** – und genau das ist der Grund, warum sie in den Vortests je nach Zielgröße die Plätze tauschen. Random Forest und XGBoost können nicht extrapolieren: Jenseits des gesehenen Bereichs geben sie den Randwert des letzten Blatts zurück, rechnen also mit 65 % statt 78 %. Ridge rechnet linear weiter – manchmal richtig, manchmal weit daneben. Bei *einsaetze_je_1000_ew* führt das zu einer Streuung von $\pm 0,89$ bei Ridge gegenüber $\pm 0,19$ bei Random Forest.

Fold	Testzeilen ausserhalb	am häufigsten betroffen
1	6,1 %	log_bevoelkerung
2	16,7 %	anteil_altbau_vor_1940_pct
3	50,0 %	anteil_wohngebaeude_pct, log_kriminalitaetsindex
4	34,8 %	anteil_wohngebaeude_pct, log_bevoelkerung
5	49,1 %	anteil_altbau_vor_1940_pct

Empfehlung: als Limitation dokumentieren, nicht wegrechnen. Der Effekt ist eine echte Eigenschaft der Fragestellung. Ihn zu dämpfen – etwa durch Kappen der Vorhersagen – wäre ein Eingriff, der den Vergleichsverfahren verwässert. Stattdessen gehört er in die Diskussion: Dass Baumverfahren bei unbekannten Stadtteilen strukturell im Nachteil sind, ist selbst ein Vergleichsergebnis.

3. R-1: Wie man die Verfahren doch noch unterscheiden könnte

Die naheliegende Antwort auf große Streuung ist der **gepaarte** Vergleich: Alle drei Verfahren sehen identische Folds, also lässt sich je Fold die Differenz bilden. Ein Fold, in dem zufällig Tenderloin liegt, ist für alle Verfahren schwer – dieser gemeinsame Anteil kürzt sich in der Differenz heraus. Das ist der Standard nach Demšar (2006) und Nadeau & Bengio (2003).

Nachgerechnet auf *anzahl_einsaetze*, 4 Wiederholungen à 5 Folds:

Größe	Wert	Lesart
Ridge, einzeln	$+0,078 \pm 0,627$	sehr instabil
Random Forest, einzeln	$+0,036 \pm 0,443$	sehr instabil
Differenz je Fold (gepaart)	$+0,042 \pm 0,609$	die Paarung hilft hier nicht
Ridge gewinnt in	12 von 20 Folds	Münzwurf

Der gepaarte Vergleich rettet die Aussage also nicht: Die Differenz streut fast genauso stark wie die Einzelwerte. Der Grund ist R-2 – die Verfahren reagieren auf *unterschiedliche* Stadtteile unterschiedlich, es gibt kaum gemeinsame Schwierigkeit, die sich herauskürzen liesse.

Was in der Modellierung trotzdem zu versuchen ist

- a) Wiederholte Splits auf 10 Durchläufe erhöhen.** 50 Fold-Ergebnisse statt 5 verengen das Konfidenzintervall des Mittelwerts spürbar, auch wenn die Einzelstreuung bleibt.
- b) Gepaarten Wilcoxon-Test rechnen** statt die Streuungsbereiche nur zu vergleichen. Er prüft die Vorzeichen der Differenzen und ist gegen Ausreisser robust.
- c) Je Zielgröße getrennt entscheiden.** Bei *einsaetze_je_1000_ew* lag Random Forest mit $0,584 \pm 0,19$ deutlich vor Ridge mit $-0,087 \pm 0,89$ – dort ist die Aussage möglicherweise belastbar, bei der absoluten Zahl nicht.
- d) Wenn es nicht reicht: als Ergebnis berichten.** „Bei 35 Analyseeinheiten sind die Unterschiede nicht von null zu trennen“ ist eine wissenschaftliche Aussage. Das Gutachten belohnt unter R6 und R9 genau diese Ehrlichkeit.

4. Was in die Sprechstunde gehört

Punkt	Was entschieden wurde	Warum es abgestimmt gehört
Stadtteil-Split statt Zeitschnitt	5 Folds à 6 Stadtteile, 6 Stadtteile Hold-out	Unterfrage 2 des Exposés nennt zeitreihengerechte Kreuzvalidierung. Die entfällt als Hauptvergleich, weil sie die Forschungsfrage nicht prüft.
Einsatzart auf Stadtteilebene	dominante Einsatzart je Stadtteil-Monat	Auf Einzeleinsatz-Ebene lag die Obergrenze bei 49,9 % gegenüber 48,2 % für blosses Raten. Die Klasse bleibt echt, nur die Analyseeinheit wechselt.
Logistische Regression statt Ridge	in der Klassifikation	Sachlich das richtige Gegenstück, aber ein anderes Verfahren. Unerwähnt wäre es der Gutachten-Kritikpunkt „heterogene Spezifikationen“ (R1).
Rate als zweite Zielgröße	Einsätze je 1.000 Einwohner	Für einen Vergleich zwischen unterschiedlich grossen Stadtteilen die ehrlichere Größe. Erweitert das Exposé, widerspricht ihm nicht.

5. Was abgeschlossen ist

Anforderung	Stand
Ein Befehl erzeugt beide Datensätze	erfüllt – python prep/build.py, 19 s
Beide auf derselben Analyseeinheit (R1)	erfüllt – Stadtteil × Monat, identische Folds
Keine zeitgleichen Merkmale (R3)	erfüllt – ACS-Versatz, Crime-Fenster im Vormonat
Aufteilung im Datensatz gespeichert (R1)	erfüllt – Spalten fold, ist_holdout
Echtes Hold-out (R5)	erfüllt – 6 Stadtteile, unberührt
Baselines für beide Stränge (R6)	erfüllt – inkl. Mehrheitsklasse
Baseline in der Data Preparation (Schröter)	erfüllt – prep/s3_baselines.py
Keine Ergebnisvariablen im Datensatz (R3)	erfüllt – per Test abgesichert
Modellfertig ohne Nacharbeit	erfüllt – float64, keine NaN
Absicherung	18 von 18 Prüfungen

Bewusst nicht enthalten

Skalierung, Imputation und Resampling bleiben bewusst **ausserhalb** der Datensätze. Sie werden aus Daten gelernt und gehören deshalb in die sklearn-Pipeline je Fold – sonst entsteht Leakage über die Foldgrenzen. Die Anforderungen dafür stehen in *docs/04_MODELLIERUNG.md*.