

Zielvariablen: Menge der Einsatzlast

data/processed/regression.parquet · 4.620 Zeilen × 25 Spalten · eine Zeile = ein Stadtteil in einem Monat

Frage: Haben Stadtteile mit höherer Armutsquote, mehr Risikogebäuden oder höherer Kriminalität **mehr Einsätze**?

Aufgabe: Regression – vorhergesagt wird eine Zahl.

So sehen die Daten aus

stadtteil	jahr_monat	anzahl_einsaetze	einsaetze_je_1000_ew	armutsquote_pct	log_krimin.index	fold
Bayview Hunters Point	201501	131	3,49	0,2249	-0,011	0
Bernal Heights	201501	59	2,28	0,0872	-0,692	1
Castro/Upper Market	201501	83	5,30	0,0748	+0,189	1
...	...	...	...	...	...	...

Die zwei Zielvariablen

Spalte	Was drinsteht	Verteilung	Warum beide?
anzahl_einsaetze	Einsätze in diesem Stadtteil-Monat, ganze Zahl	Mittel 75,9 Median 53 Max 451	Die Größe aus dem Exposé. Zähldaten mit Dispersionsindex 62,8 – stark überdispers, deshalb Negative Binomial statt Poisson als Baseline.
einsaetze_je_1000_ew	dieselbe Zahl, geteilt durch die Einwohner	Mittel 5,71 Median 3,54 Max 67,7	Für den Vergleich <i>zwischen</i> unterschiedlich großen Stadtteilen die ehrlichere Größe: Die absolute Zahl bildet vor allem die Einwohnerzahl ab.

Die restlichen Spalten

Gruppe	Spalten	Rolle
Schlüssel	stadtteil, jahr, monat, jahr_monat	Wer und wann – keine Merkmale
Merkmale (12)	median_haushaltseinkommen, armutsquote_pct, akademikerquote_pct, median_miete, leerstandsquote_pct, log_bevoelkerung, log_kriminalitaetsindex, anteil_altbau_vor_1940_pct, anteil_wohngebaeude_pct, anteil_risikogewerbe_pct, monat_sin, monat_cos	Was ins Modell geht.
Lags (3)	lag_1, lag_12, rolling_mean_3	Kein Modellmerkmal. Wäre unter dem Stadtteil-Split die eigene Vergangenheit des Teststadtteils.
Rohwerte	gesamtbevoelkerung, kriminalitaetsindex	Kein Merkmal. Nenner für den NegBin-Offset und die Deskription.
Aufteilung	fold (0–5), ist_holdout (0/1)	Steht in der Datei, damit alle drei Verfahren zwingend dieselben Folds sehen.

Passt zu allen drei Algorithmen

Alle drei Verfahren können diese Aufgabe direkt rechnen: **Ridge**, **RandomForestRegressor**, **XGBRegressor**. Gütemaße: RMSE, MAE, R^2 .

Zielvariablen: Struktur der Einsatzlast

data/processed/klassifikation.parquet · 4.619 Zeilen × 29 Spalten · dieselbe Zeile wie links, ein Stadtteil-Monat ohne Einsatz fällt weg

Frage: Haben Stadtteile mit bestimmten Strukturmerkmalen eine **andere Art** von Einsätzen – mehr Brände, mehr Fehlalarme?

Aufgabe: Klassifikation (welche Art dominiert) und Regression (wie hoch ist der Anteil).

So sehen die Daten aus

stadtteil	jahr_monat	anzahl_einsaetze	anzahl_brand	anzahl_fehleralarm	anteil_brand	anteil_fehleralarm	dominante_einsatzart
Bayview Hunters Pt.	201501	131	29	50	0,221	0,382	fehleralarm
Bernal Heights	201501	59	8	29	0,136	0,492	fehleralarm
Castro/Upper Mkt.	201501	83	22	39	0,265	0,470	fehleralarm
...	...	...	...	...	...	...	...

Die Zielvariablen

Spalte	Typ	Was drinsteht	Verteilung
dominante_einsatzart	4 Klassen Klassifikation	Welche der vier NFIRS-Gruppen in diesem Stadtteil-Monat am häufigsten war. <i>argmax</i> über die vier Anteile – eine echte Klasse, kein gesetzter Schwellwert.	fehleralarm 79,0 % techn. Hilfe 16,3 % rettung_ems 3,1 % brand 1,5 %
anteil_brand anteil_rettung_ems anteil_technische_hilfe anteil_fehleralarm	stetig in [0,1] Regression	Anteil der jeweiligen Gruppe an allen Einsätzen des Monats. Die vier summieren sich je Zeile auf 1.	im Mittel 11,6 % · 14,9 % 26,2 % · 47,4 %

Die vier *anzahl_**-Spalten sind die Zählungen dahinter (Summe = *anzahl_einsaetze*), keine Modellmerkmale. Die **Merkmale sind identisch** mit denen der Mengentabelle, ebenso die Folds – nur die Zielvariable wechselt.

Warum diese Ebene und nicht der einzelne Einsatz?

Ebene	Zeilen	verschiedene Merkmalsprofile	Was ein perfektes Modell erreicht
Einzeleinsatz (<i>verworfen</i>)	350.481	nur 4.619	49,9 % Accuracy – gegenüber 48,2 % für bloßes Raten. Obergrenze: 1,7 Prozentpunkte .
Stadtteil × Monat	4.619	4.619	Jede Zeile ist eine eigene Beobachtung. Der Fehlalarm-Anteil ist für einen unbekannten Stadtteil mit R^2 0,66 vorhersagbar.

Innerhalb eines Stadtteil-Monats tragen *alle* Einsätze dieselben Strukturmerkmale. Die zusätzlichen Zeilen bringen keine zusätzliche Information, nur scheinbare Stichprobengröße.

Ein Verfahren passt nicht direkt

Ridge kann diese Aufgabe nicht direkt rechnen – es ist ein Regressionsverfahren. Für die Klassifikation tritt die logistische Regression mit L2-Strafterm an seine Stelle: dasselbe Regularisierungsprinzip, andere Link-Funktion. Das **muss im Text benannt werden**, sonst ist es der Gutachten-Kritikpunkt „heterogene Spezifikationen“. Random Forest und XGBoost haben beide eine Classifier-Variante.

Die vier *anteil_**-Zielgrößen sind dagegen stetig – dort rechnen alle drei Verfahren wieder direkt.